

u^b

b
**UNIVERSITÄT
BERN**

Ein empirischer Ansatz zur Eingrenzung modellübergreifender Unsicherheiten in der Schätzung zwischenjährlicher Schwankungen globaler Bruttoprimärproduktion

BACHELORARBEIT

PHILOSOPHISCH-NATURWISSENSCHAFTLICHE FAKULTÄT,
UNIVERSITÄT BERN

Eingereicht durch
Timo Trinidad

August 2025

Betreuer:

Prof. Dr. Benjamin Stocker

Geographisches Institut, Universität Bern

Zusammenfassung

Terrestrische Ökosysteme bildeten über die vergangenen Dekaden eine substanzielle Senke im Kohlenstoffaustausch mit der Atmosphäre und trugen damit entscheidend dazu bei, die Akkumulation anthropogener CO₂-Emissionen zu verlangsamen. Die terrestrische CO₂-Speicherung unterlag dabei bedeutenden zwischenjährlichen Schwankungen, die sich umfassend auf entsprechende Fluktuationen in der photosynthetischen Kohlenstoffaufnahme zurückführen lassen. Obwohl die klimatischen Determinanten und geographischen Treiber hinter diesen Schwankungen heute weitgehend eingegrenzt sind, bestehen nach wie vor grosse Unsicherheiten bei der Simulierung dieser durch satellitengestützte Modelle. In der vorliegenden Arbeit grenzen wir diese Unsicherheiten durch einen Emergent-Constraint-Ansatz ein. Dabei stützen wir uns auf die Kopplung zwischenjährlicher Variabilität der Bruttprimärproduktion mit jener der Landsenke, die vorausgehende Untersuchungen für prozessierte Ökosystem-Modelle aufgezeigt haben. Wir berechnen die simulierte zwischenjährige Variabilität der Bruttprimärproduktion und Landsenke für ein umfassendes Sets von über 50 Modelloutputs und zeigen bedeutende modell- und simulationsbezogene Unterschiede in der Stärke ihres Zusammenhangs auf. Schliesslich legen wir diesen mit dem Wert der beobachteten zwischenjährlichen Variabilität der Landsenke bei 1.2 Pg C yr^{-1} fest, um einen modellübergreifenden Unsicherheitsbereich in jener der Bruttprimärproduktion zwischen $1.8 - 4.7 \text{ Pg C yr}^{-1}$ einzugrenzen.

Inhaltsverzeichnis

1 Einleitung	1
2 Konzeptionelle Ansätze zur Schätzung von GPP und NBP	4
2.1 Prozessbasierte Modelle	4
2.2 RS-basierte Modelle	7
3 Methodik	11
3.1 Emergent-Constraint-Ansatz	11
3.2 Datenlage	12
3.2.1 TRENDY	12
3.2.2 CMIP	13
3.2.3 MsTMIP	13
3.2.4 FLUXCOM	14
3.2.5 P-Model	14
4 Ergebnisse	16
4.1 Jährliche Absolutwerte, Trends und Variationskoeffizienten	16
4.1.1 TRENDY	16
4.1.2 CMIP	17
4.1.3 MsTMIP SG1	20
4.1.4 MSTMIP SG3	22
4.2 Restringiertes GPP-IAV-Interval	25
5 Diskussion	29
6 Literaturverzeichnis	31
Daten- und Codeverfügbarkeit	40
Selbstständigkeitserklärung	41
A Ergänzendes Material	42
A.1 Übersicht aller berücksichtigter Modelle	42
A.2 Landkomponenten der CMIP-Modelle	43

A.3 Landkomponenten der CMIP-Modelle	44
--	----

1 Einleitung

2024 verzeichnete den höchsten Einjahresanstieg in atmosphärischem CO₂ seit Messbeginn (Lan et al., 2025). Zwischenjährliche Anomalien der atmosphärischen CO₂-Wachstumsrate gehen dabei entscheidend auf Schwankungen in terrestrischer Kohlenstoff-Bindung über den selben Zeitraum zurück (Knorr et al., 2007; Le Quéré et al., 2018; Pei et al., 2022). Bruttoprimärproduktion (GPP – *Gross Primary Production*) als die Menge des von Ökosystemen durch Photosynthese aufgenommenen CO₂s (Keenan and Williams, 2018) ist in dessen zwischenjährlicher Variabilität (IAV - *Interannual Variability*) über mehrere Feedback-Prozesse selbst wiederum eng an klimatische Variabilität gebunden (Humphrey et al., 2018; Cox et al., 2013; Reichstein et al., 2013; Poulter et al., 2014; Ahlström et al., 2015). Vor diesem Hintergrund hält eine akkurate Abbildung der IAV von GPP wichtige Informationen sowohl über die Treiber als auch über die Auswirkungen des anthropogenen Klimawandels bereit (Keenan et al., 2016) – und weist damit eine wichtige Fähigkeit aus, die es bei der Evaluierung der Performance von GPP-Modellen zu berücksichtigen gilt (Keenan et al., 2012; Anav et al., 2015).

Eine Vielzahl der über die vergangenen Jahre vorgelegten GPP-Schätzungen auf regionaler und globaler Ebene basiert auf Fernerkundungsmodellen (RS-Modelle – *Remote Sensing Models*). Viele RS-Modelle leiten GPP auf Grundlage der Gleichung der Lichnutzungseffizienz (LUE – *Light Use Efficiency*) her. Diese formuliert GPP als Produkt der an der Vegetationsoberfläche eintreffenden photosynthetisch aktiven Strahlung und LUE, der Effizienz mit der absorbierte Photonen für die Bindung von CO₂ verwertet werden (Monteith, 1972). Obwohl Studien deren Outputs immer wieder als Beobachtungsdaten ausweisen und zum Benchmarking von Schätzungen prozessbasierter Modelle heranziehen (bspw. bei Zhang et al., 2009) weisen diese nach wie vor grosse Unsicherheiten bei der Abbildung zwischenjährlicher Variabilität auf (Zheng et al., 2020). Yuan et al. (2014), die die Schätzungen von sieben LUE-Modellen gegen CO₂-Fluss-Messungen an 51 Eddy-Covariance-Messstellen evaluieren, finden eine erklärte GPP-IAV im geringen Bereich von 6% - 36%. Weiter zeigt ein Vergleich von Keenan et al. (2012) für die Schätzungen in elf nordamerikanischen Wäldern signifikante Verfehlungen beobachteter GPP-IAV-Werte in allen drei berücksichtigten RS-Modellen. Schliesslich finden Stocker et al. (2019) für ein Ensemble führender RS-Modelle eine systematische Unterschätzung der GPP-IAV über die gesamte bewachsene Landfläche.

Ein Kernanliegen vieler Innovationen in LUE-basierten GPP-Modelle der vergangenen Jahre bestand darin, LUE Biom-, Prozess- (C3- ggü. C4-Pflanzen) und Licht-spezifisch (besonnte ggü. beschattete Blätter) zu formulieren und akkurate Umweltstressfunktionen für Temperatur, Wasserverfügbarkeit und CO₂-Konzentration einzuführen. Besonders die Formulierung letzterer bleiben mit grossen Unsicherheiten verbunden (Pei et al., 2022) in Folge dessen die Auswirkungen der Variabilität in Umweltfaktoren auf LUE in vielen RS-basierten GPP-Produkten unzureichend repräsentiert sind (Yuan et al., 2014; Bloomfield et al., 2023). So modellieren RS-Modelle den Einfluss steigender CO₂-Konzentrationen in der Regel ausschliesslich über Änderungen in der absorbierten photosynthetisch aktiven Einstrahlung, berücksichtigen damit aber nicht die primären biochemischen Auswirkungen durch den Anstieg in LUE (De Kauwe et al., 2016). Weiter bleibt der regulierende Einfluss von Wasserverfügbarkeit in gewissen Modellen ausschliesslich über Niederschlagsdaten berücksichtigt, obwohl Evidenz vorliegt, dass primär Veränderungen im atmosphärischen Wasserdampf-Defizit (*VPD – Vapour Pressure Deficite*) die Vegetationsproduktivität beeinflussen (Konings et al., 2017). Andere Modelle schliesslich, die zwar atmosphärische Wasserverfügbarkeit akkurat abzubilden vermögen, vermitteln Wasserstress dann jedoch oft ausschliesslich über VPD und die absorbierte photosynthetisch aktive Strahlung, obwohl vergangenen Untersuchungen aufzeigten, dass diese die pflanzenphysiologischen Auswirkungen von tiefen Bodenfeuchtewerten nur unzureichend modelliert (Stocker et al., 2019).

Einen anderen Ansatz zur Schätzung von GPP verfolgen prozessbasierte Modelle: Diese stützen sich nicht auf externe Beobachtungsdaten der Vegetationsoberfläche zur Schätzung des absorbierten Anteils eintreffender photosynthetisch aktiver Strahlung, sondern prognostizieren diese intern. Dabei simulieren sie das terrestrische Ökosystem als ein Set nacheinander geschalteter Speicher, durch die Kohlenstoff kaskadisch zirkuliert. GPP bildet den System-Input, wobei sich durch das Prinzip der Massenerhaltung Schwankungen in dieser in nachfolgenden Fluss- und Speichergrössen fortpflanzen (vgl. Kapitel 2.1). Ahlström et al. (2015) zeigen diese Kopplung für ein Set führender prozessbasierter Modelle empirisch auf. Sie finden eine Median-Assoziation der IAV globaler NBP mit jener in GPP von 90%. Wir bauen auf diese Resultate auf und kombinieren den modellierten Zusammenhang zwischen IAV-GPP und -NBP aus einem umfassenden Set führender prozessbasierter Modelle mit der beobachteten IAV in NBP, um ein restrianziertes Intervall

der IAV in GPP abzuleiten. Im folgenden Kapitel diskutieren wir die unterschiedlichen konzeptionellen Ansätze, auf denen prozessbasierte und RS-Modelle basieren, genauer. Anschliessend stellen wir unsere Methodik entlang des Emergent-Constraint-Ansatzes und die der Analyse zu Grund liegenden Daten vor. Schliesslich stellen wir unsere Ergebnisse vor und diskutieren deren Implikationen.

2 Konzeptionelle Ansätze zur Schätzung von GPP und NBP

GPP lässt sich über die Skala der Blattebene hinaus nicht direkt messen (Welp et al., 2011). Vor diesem Hintergrund verwiesen Cramer et al. bereits 1999 auf eine breite Palette von Modellen sehr unterschiedlicher Komplexität, um GPP global zu schätzen. De et al. (2025) unterscheiden heute drei Stränge biogeochemischer Modelle zur Simulierung von GPP: Prozessbasierte Modelle, wie sie die Vergleichsreihe der Trends-and-Drivers-of-Terrestrial-Sources-and-Sinks-of-Carbon-Dioxide (TRENDY) versammelt Sitch et al. (2024), beschreiben Photosynthese und Respiration mikrofundiert-mechanistisch und leiten fAPAR aus dem intern simulierten Blattflächenindex her. Im Gegensatz dazu stützen sich RS-Modelle zur Abbildung der Vegetationsbedeckung auf externe Beobachtungsdaten, um fAPAR diagnostisch abzuleiten. Die angeführte Typologie unterscheidet sie weiter in semiempirische Modelle, die GPP entlang der LUE-Gleichung (Monteith, 1972) berechnen, und datengetriebene Modelle, wie dem FLUXCOM-Ansatz Jung et al. (2020), die GPP durch die Skalierung einer Vielzahl von Punktmessungen schätzen. In diesem Kapitel gehen wir auf die unterschiedlichen konzeptionellen Herangehensweisen der angeführten Modelltypen ein. Dabei konzentriert sich die Diskussion der RS-Modelle mit der Ausbreitung des LUE-Ansatzes hauptsächlich auf semiempirische Modelle.

2.1 Prozessbasierte Modelle

Prozessbasierte Modelle beschreiben das terrestrische Ökosystem als ein Set nacheinander geschalteter Speicher durch die photosynthetisch assimilierter Kohlenstoff unter Massenerhaltung und reguliert durch Umwelteinflüsse kaskadisch zirkuliert, um schliesslich wiederum als CO₂ an die Atmosphäre abgegeben zu werden (Stocker, 2024). Entlang dieses konzeptionellen Ansatzes koppeln sie Kohlenstoff-Flüsse und -Speicher im System in ähnlicher Weise, was in robusten Schätzungen der Zusammenhangs zwischen der Variabilität des Input-Flusses (GPP) und jener des Speichers (NBP) resultiert. Im folgenden wollen wir diesen konzeptionellen Ansatz mit der Herleitung eines einfachen Ökosystem-Modells weiter ausführen, um schliesslich auf zentrale Dynamiken in den durch diese abgebildeten Systemen einzugehen.

Ein Grundlegendes Prinzip, das allen Ökosystem-Modellen unterlegt ist, ist jenes der

Massenerhaltung. Sie besagt, dass über einen bestimmten Zeitraum der Input in einen Speicher der Summe aus Speicheränderung und Output aus dem Speicher entspricht (Ågren and Andersson, 2011). Auf dieser Grundlage lässt sich die Änderung des Speichers wiederum als Differenz aus Input und Output formulieren;

$$\frac{dX(t)}{dt} = I(t) - O(t), \quad (1)$$

wobei $X(t)$ den Speicher, $I(t)$ den Input und $O(t)$ den Output jeweils über die Zeit repräsentieren. Für lineare dynamische Systeme kann $O(t)$ als lineare Funktion der Speichergrösse ausgedrückt und damit (1) als einfache Differentialgleichung umgeschrieben werden;

$$\frac{dX(t)}{dt} = I(t) - kX(t), \quad (2)$$

wobei k die Verfallsrate des Speichers beschreibt (Stocker, 2024). Prozessbasierte Ökosystem-Modelle lassen sich nun als eine strukturierte Sammlung vieler solcher Differentialgleichungen fassen, die jeweils einen bestimmten Speicher repräsentieren. Die Flüsse zwischen den Speichern werden vor dem Hintergrund der Massenerhaltung dadurch beschrieben, dass der Output eines Speichers einen Teil des Inputs eines nachgeschalteten Speichers konstituiert (Schulze et al., 2019).

Ein für die Mehrheit der heute vorliegenden Ökosystem-Modelle repräsentatives Modell stellen Luo and Weng (2011) vor. Sie formulieren ihr Modell wie folgt:

$$\frac{d\mathbf{X}(t)}{dt} = U(t) \times \mathbf{b} + \epsilon(t) \times \mathbf{A} \times \mathbf{C} \times \mathbf{X}(t). \quad (3)$$

Hier beschreibt der Vektor \mathbf{X} die Grösse aller berücksichtigten Speicher. U ist die Menge des photosynthetisch gebundenen Kohlenstoffs, die multipliziert mit \mathbf{b} , einem Vektor von Allokationskoeffizienten, für jeden nachgeschalteten Speicher in \mathbf{X} die Kohlenstoff-Inputmenge definiert. Äquivalent zu k aus (2) führt die Matrix \mathbf{C} speicherspezifische Verfallsraten, die multipliziert mit der Speichergrösse den Output definieren. An dieser Stelle ist die Verfallsrate weiter mit der Matrix \mathbf{A} , welche die Raten der Kohlenstoff-transfers zwischen den Speichern führt, multipliziert. Schliesslich beschreibt die Funktion $\epsilon(t)$ die Regulierung von Kohlenstofftransfer und -verfall durch Umweltdeterminanten (Schulze et al., 2019). Ihre Komplexität gewinnen prozessbasierte Modelle nun durch

die mikrofundierte Abbildung pflanzenphysiologischer und mikrobieller Vorgänge. Im Gegensatz zu RS-Modellen, die GPP über den Zeitraum von Wochen und Monate auf Ökosystem-Ebene schätzen, basiert U in vielen Ökosystem-Modellen auf der skalierten Abbildung zellphysiologischer Prozesse nach dem Farquhar-von-Caemmerer-Berry-Model (FvCB) (Yuan et al., 2024). Nach der Assimilation liegt Kohlenstoff zunächst als Zucker vor. Während ein Teil dieses im Zuge autotropher Respiration sogleich mobilisiert wird um die für die Aufrechterhaltung physiologischer Funktionen, Wachstum und Photosynthese benötigte Energie bereit zu stellen, steht ein zweiter Teil als sog. Nettoprimärproduktion (NPP) zur Bildung neuer Biomasse zur Verfügung (Stocker, 2024). Die Allokation von NPP in einzelne Speicher – es gibt eine grosse Bandbreite an Speichern, die unterschiedliche Ökosystem-Modelle berücksichtigen (Schulze et al., 2019) – kann dabei festdefinierten Anteilen folgen oder auf einer Optimalitätsregel basieren, nach der die Allokation von Kohlenstoff dynamisch auf Grund der Verfügbarkeit von Licht, Wasser und Nährstoffen erfolgt (Franklin et al., 2012). Unterschiedliche Verfallsraten in \mathbf{C} reflektieren, dass der zugeordnete Kohlenstoff in unterschiedlichen Speichern unterschiedlich lange verweilt, bevor er im Zuge von Respirationsprozessen abgebaut wird. Diese Verfallsraten sind – wenn auch unterschiedlich stark – an klimatische Fluktuationen gebunden und können damit ausgeprägten saisonalen und zwischenjährlichen Schwankungen unterliegen. Viele Ökosystem-Modelle berücksichtigen aus diesem Grund Funktionen wie $\epsilon(t)$, mit denen der Einfluss von Temperatur, Bodenfeuchte und weiteren Umweltfaktoren abgebildet werden soll. Diese Funktionen können empirisch hergeleitet oder auf physiologischen resp. mikrobiellen Prinzipien beruhen und sind oftmals multiplikativ formuliert (Schulze et al., 2019).

Lineare Modelle wie das hier eingeführte konvergieren stets gegen einen Gleichgewichtszustand. Eine wichtige Konsequenz des Zerfall-Modells erster Ordnung, wie wir es in (2) mit der Formulierung des Outputs als lineare Funktion der Speichergrösse implizieren, ist die lineare Abhängigkeit der Änderung des Gleichgewichtspeichers dX von der Änderung im Input dI (Stocker, 2024). Wie im Methodik-Kapitel weiterführend dargelegt, stützt sich unser Ansatz entscheidend auf diesen Zusammenhang. So regulieren Umweltveränderungen über $\epsilon(t)$ die Raten in \mathbf{A} und \mathbf{C} , modifizieren damit den Input nachgeschalteter Speicher und regen schliesslich eine Verschiebung der Gleichgewichtszustände an. Dabei gehen tiefere Verfallsraten mit höheren Gleichgewichtszuständen und längeren Zeitspannen zur

Erreichung dieser einher. Störungen wie Feuer oder Unwetter können Kohlenstoffspeicher vorläufig stark reduzieren. Bei konstanten Transfer- und Verfallsraten in \mathbf{A} resp. \mathbf{C} und gleichbleibenden Inputraten ($U \times \mathbf{b}$) konvergiert das System wiederum gegen den ursprünglichen Gleichgewichtszustand (Schulze et al., 2019).

2.2 RS-basierte Modelle

Die zunehmende Verfügbarkeit von Satellitenbeobachtungen mit hoher zeitlicher und spektraler Auflösung und bei globaler Abdeckung hat die methodischen Möglichkeiten zur quantitativen Beschreibung terrestrischer Kohlenstoffflüsse und -speicher über die vergangenen Dekaden entscheidend erweitert (Hilker et al., 2008). Heute basiert die Mehrzahl der vorliegenden GPP-Schätzungen auf Fernerkundungsmodellen (Wang et al., 2024). Im Gegensatz zu prozessfundierten Modellen, die die Vegetationsbedeckung modellinherent simulieren, diagnostizieren RS-basierte Modelle Vegetation aus externen Fernerkundungsprodukten (Wang et al., 2014). Satellitenbasierte Schätzung von GPP stützen sich auf drei zentrale Annahmen; zunächst auf die Idee, dass der Umfang terrestrischer Photosynthese direkt von der absorbierten solaren Einstrahlung abhängt, weiter auf die Theorie, dass eine Beziehung zwischen der absorbierten solaren Einstrahlung und den satellitengewonnenen spektralen Indizes (bspw. dem NDVI) besteht und schliesslich auf die Annahme, dass es biophysische Faktoren gibt, die die Effizienz, mit der solare Energie in Biomasse transformiert wird, moderieren (Running et al., 2004). Die theoretische Fundierung dazu bildet das LUE-Modell, das sich auf Untersuchungen von John Monteith stützt (u.a. (Monteith, 1972)). Monteith beobachtete eine lineare Abhängigkeit der Biomasse-Produktivität von Pflanzen ggü. eintreffender solarer Einstrahlung, wobei über Ökosysteme hinweg diese Beziehung durch unterschiedliche Energienutzungseffizienzen moderiert wurde. Um Monteiths Beziehung auf GPP zu beziehen, machen sich RS-Modelle nun zu nutze, dass sich die von Pflanzen über den Zeitraum von Wochen bis Monate assimilierte Menge CO₂ proportional zur Solarstrahlung, integriert über den selben Zeitraum, verhält (Stocker, 2024). So wird GPP als Produkt der am Vegetationsdach eintreffenden solaren Einstrahlung im photosynthetisch aktiven Spektrum zwischen 400 – 700 nm (*PAR*), des Anteils dieser, der durch die aktive Blattoberfläche absorbiert wird (*fAPAR*), und der eigentlichen

Lichtnutzungseffizienz (*LUE*) formuliert:

$$GPP = PAR \times fAPAR \times LUE. \quad (4)$$

Den Ausführungen von Stocker (2024) folgend, wollen wir die Komponenten der LUE-Gleichung nun individuell herleiten:

PAR, hier ausgedrückt als Energiefluss pro Bodenfläche und Zeit, ist ein Anteil der an der Atmosphärenobergrenze eintreffenden solaren Einstrahlung. Dieser hängt zum einen von der planetaren Albedo als dem Verhältnis zwischen reflektierter zu einfalender Strahlung über einen bestimmten Wellenlängenbereich ab. Zum anderen wird die Menge kurzwelliger Einstrahlung durch atmosphärische Streuung und Absorption reduziert. Diese Reduktion nimmt in der Länge des Transmissionspfad und der Stärke der Wolkenbedeckung zu (Brönnimann, 2018). Schliesslich ist nun bloss jener im zuvor erwähnten Wellenlängenbereich liegende Anteil der an der Vegetationsoberfläche eintreffenden Strahlung photosynthetisch nutzbar. Diesem entsprechend ist auch der Albedo-Wert formuliert. Räumliche und zeitliche Variationen in *PAR* folgen stark jenen der an der Atmosphärenobergrenze eintreffenden solaren Strahlung (Stocker, 2024).

fAPAR als jener Anteil von *PAR*, der durch die Vegetation absorbiert wird, hängt von der projizierten aktiven Blattoberfläche pro Einheit Bodenfläche (LAI) ab. LAI ist auf Ökosystem-Ebene definiert und reflektiert die Blattoberflächendichte des gesamten Vegetationsdachs. LAI beeinflusst dabei auch, wie stark die am Vegetationsdach eintreffende solare Einstrahlung bei der Transmission durch die Krone bis zum Boden reduziert wird (Stocker, 2024).

LUE beschreibt schliesslich, wie effizient die absorbierte Energie genutzt wird, um den aus der CO₂-Bindung gewonnenen Kohlenstoff in Zucker umzusetzen. Wie *fAPAR* ist *LUE* auf Ökosystem-Ebene formuliert, reflektiert also übergeordnet die photosynthetische Effizienz der Blätter eines Vegetationsdachs. Diese spiegelt nicht nur physiologische Prozesse auf Blattebene wieder, sie bildet auch die Regulierung des photosynthetischen Apparates durch Umweltvariablen ab. So ist die Diffusion von CO₂ durch die Öffnung der Blattstomata reguliert, welche wiederum von den Umgebungsbedingungen der Pflanze abhängt. Dabei steigt die Assimilation von CO₂ linear in der Differenz zwischen atmosphärischer und blattinterner CO₂-Konzentration. Auch die Geschwindigkeiten der drei photosynthetischen Prozesse - Lichtabsorption, Lichtreaktionen und Calvin-Zyklus – sind stark durch Umwelt-

bedingungen reguliert. Dabei bedingt die Rate des am langsamsten ablaufenden Prozesses die Geschwindigkeit der Photosynthese als ganzes. Stark vereinfachende Modelle, in denen LUE konstant gehalten wird, die sich damit ausschliesslich auf Variation in fAPAR stützen, bilden etwa 76% der in Flussmessungen beobachteten GPP-Fluktuationen auf Ökosystem-Ebene ab (Stocker, 2024). In komplexeren Modellen ist das in (4) aufgeführte LUE als *tatsächliches LUE* konzeptualisiert, das unter Regulierung von Umweltbedingungen aus einem theoretisch maximalen LUE-Wert abgeleitet wird. So folgt

$$LUE = LUE_0 \times f(T, W, \dots), \quad (5)$$

wobei LUE_0 das theoretisch maximale LUE und $f(T, VPD, \dots)$ eine Regulierungsfunktion in Abhängigkeit von Umwelteinflüssen wie bspw. Temperatur oder atmosphärischem Dampfdruck darstellen. RS-Produkte, die GPP auf globaler Ebene schätzen, stützen sich oft auf biomspezifische Werte für LUE_0 . So übernehmen diverse Modelle die LUE_0 -Werte des MODIS-Modells, das elf unterschiedliche Biome unterscheidet (Zhao et al., 2005). Darüber hinaus unterscheiden bestimmte Modelle unterschiedliche LUE_0 -Werte für C3- und C4-Pflanzen. Schliesslich inkorporieren einzelne die Ergebnisse jüngerer Studien (so bspw. (He et al., 2013), die signifikante LUE_0 -Unterschiede zwischen sonnigen und beschatteten Pflanzen feststellen. Wie einleitend erwähnt, bleibt die Abbildung von Umwelteinflüssen auf LUE_0 mit grossen Unsicherheiten verbunden. Heute berücksichtigen die meisten Modelle multiplikative Stressfunktionen für zwei bis drei Umweltvariablen, wobei sich diese in den herangezogenen Prozessen von Modell zu Modell stark unterscheiden. Ein zentrales Problem bleibt die Abbildung der komplexen Auswirkungen von Wasserstress auf GPP (Pei et al., 2022). Einen alternativen Ansatz zur Schätzung von GPP wird mit dem P-Modell verfolgt (Wang et al., 2017; Prentice et al., 2014; Stocker et al., 2020). Statt diskrete LUE_0 -Werte entlang empirisch gewonnener Funktionen zu skalieren, leitet dieses LUE direkt aus den physiologischen Prozessen der Photosynthese auf Blattebene ab, wie sie das Modell von Farquhar et al. (1980) beschreibt. Dabei stützt man sich auf die weiter oben erwähnte Koordinationshypothese, nach welcher sich die Raten der photosynthetischen Teilprozesse dahingehend an die vorherrschenden Umgebungsbedingungen über den Zeitraum eines Tages anpassen, dass sie gleichermassen limitierend wirken. Darauf aufbauend formulieren sie nun einen Optimalitätsprinzip-basierten Ansatz, dem zufolge Pflanzen ihre stomatäre Leitfähigkeit so regulieren, dass die kombinierten Kosten für

CO₂-Aufnahme und Wasserverlust minimiert werden (Wang et al., 2014). Obwohl das P-Modell unter Einbezug weit weniger Parameter als bei komplexen Modellen ebenbürtig oder besser performt als diese, bezieht es sich wiederum auf gut-gewässerte Bedingungen (Mengoli et al., 2023) – und bildet die IAV von GPP wie andere LUE-Modelle mangelhaft ab (Stocker et al., 2019).

3 Methodik

3.1 Emergent-Constraint-Ansatz

Die Konzeption der Landesenke als Set nacheinander geschalteter Speicher, durch die Kohlenstoff kaskadisch zirkuliert, impliziert, dass Variation in GPP auch zu Schwankungen in allen folgenden Flüssen und Speichern führt (Stocker, 2024). Ahlström et al. (2015) finden denn auch für die TRENDY-DGVMs, dass sich zwischenjährliche NBP-Schwankungen im Ensemble-Mittel zu 90% auf die IAV in GPP zurückführen lassen. Auf diesen starken Zusammenhang bauen wir im folgenden auf.

Wir beschreiben die Beziehung zwischen der IAV von GPP und NBP auf Basis einer robusten Regression. Dafür stützen wir uns auf globale Jahreswerte über eine 30-Jahres-Periode von 1982-2011 der Modelle der TRENDY- und CMIP-Reihen sowie jener der MsTMIP-SG3-Simulation. Als Mass für die IAV dient die Varianz der entsprechenden Werte nachdem diese um lineare Trends bereinigt wurden, wobei wir uns in der Diskussion von Modellunterschieden auf dessen Normalisierung um den Mittelwert der Absolutwerte (Variationskoeffizient) stützen. Da wir für NBP für diese einen Mittelwert um null erwarten, normalisieren wir in beiden Variablen jeweils mit dem Mittelwert in GPP. Die Regression der IAV-Werte in NBP auf jene in GPP folgt der Huber-Methode, die Ausreißer durch eine gewichtete Anpassung der Residuen abschwächt und robuste Schätzungen auch bei stark streuenden Verteilungen liefert (Huber, 1981). Die Unsicherheiten der geschätzten Beziehung beschreiben wir durch ein Bootstrapping-Verfahren, in Zuge dessen wir durch wiederholtes Ziehen (bei anschliessendem Zurücklegen) von GPP-NBP-Paaren aus der oben beschriebenen IAV-Grundgesamtheit eine Reihe neuer Stichproben generieren, für die wir wiederum Regressionsparameter schätzen. Schliesslich erhalten wir eine Verteilung von Regressionsgeraden unterschiedlicher Steigungen und Achsenabschnitte, auf deren Grundlage wir ein 95%-Konfidenzintervall ableiten, das für einen gegebenen GPP-IAV-Wert den Bereich ausweist, in dem das Modellensemble den korrespondierenden NBP-IAV-Wert mit entsprechender Sicherheit schätzt. Schliesslich grenzen wir diesen Bereich durch die IAV der residualen Landesenke, wie sie aus der Differenz der Summe der Emissionen aus der Verbrennung fossiler Energieträger und im Zuge von Landnutzungsänderungen ggü. den Änderungen in der ozeanischen Senke und atmosphärischer CO₂-Konzentration auf Grundlage der Kohlenstoff-Budgetgleichung folgt. Wir stützen uns dabei auf Daten des

Global Carbon Projects ((Friedlingstein et al., 2025)).

3.2 Datenlage

Unsere Analyse stützt sich auf DGVMs aus drei Vergleichsreihen sowie zwei RS-Modelle. Für einen Überblick sämtlicher berücksichtigter Modelle verweisen wir auf Anhang A.1. Im folgenden spezifizieren wir die Simulationen, mit denen wir arbeiten, genauer.

	TRENDY S3	CMIP historical	MsTMIP SG1	MsTMIP SG3
Atmosphärisches CO ₂	J	J	N	J
Klima	J	J*	J	J
Stickstoff-Deposition	J**	J	N	N
Landnutzung	J	J	N	J

Tabelle 1: Übersicht der variablen (J) resp. konstanten (N) Abbildung externer Forcings über alle berücksichtigten Simulationen. *In den CMIP-ESMs ist klimatisches Forcing intern simuliert, während dieses in TRENDY und MsTMIP auf Beobachtungsdaten beruht. **Nur ein Teil der TRENDY-Modelle führt ein Stickstoff-Modul und nutzt damit die bereitgestellten Felder. In der Tabelle in Anhang A.3 führen wir entsprechende Unterschiede auf.

3.2.1 TRENDY

TRENDY ist ein internationales *Intercomparison*-Projekt, das eine Reihe von DGVMs und Landoberflächenmodelle (LSMs – *Land Surface Models*) zu koordinierten Modell-durchläufen mit geteilten Forcing-Daten versammelt (Friedlingstein et al., 2022). Das geteilte Vorgehen erlaubt es nun, Unterschiede in den Modelloutputs direkt auf die unterschiedliche Repräsentation von Prozessen und abweichende Parametrisierungen zurückzuführen. Nicht nur wird dessen modellübergreifender NBP-Mittelwert seit 2017 als Land-Senke im Global Carbon Budget geführt (Le Quéré et al., 2018), auch nutzt eine Reihe von Untersuchungen GPP-Schätzungen aus TRENDY-DGVMs als Referenz-Werte zur Evaluierung von RS-Modellen (u.a. Wild et al., 2022). Für diese Analyse arbeiten wir mit dem Output der S3-Simulation von TRENDY-v12 (Friedlingstein et al., 2023;(Sitch et al., 2024)), dessen Forcing auf variierenden, d.h. historisch beobachteten Umweltbedingungen in atmosphärischer CO₂-Konzentration, Klimavariablen und Landbedeckungsänderung beruhen. Unsere Analyse stützt sich auf Outputs von 17 der 20 aufgenommenen Modelle. Für die Outputs von drei Modellen gelang aufgrund abweichender Grid-Formatierungen

keine räumliche Aggregation zu Globalwerten. Die Daten wurden am 08.05.2025 via dem Data-Browser des Global Carbon Budget (<https://mdosullivan.github.io/GCB/>) bezogen.

3.2.2 CMIP

Das Coupled Model Intercomparison Project (CMIP) vergleicht eine Reihe von umfassenden ESMs, die sich nicht auf die Modellierung der terrestrischen Kohlenstoffsenke beschränken, sondern diese dynamisch mit Atmosphären- und Ozeanmodellen koppeln (Durrack et al., 2025). Im Unterschied zu den ungekoppelten TRENDY-DGVMs, deren klimatisches Forcing auf Beobachtungsdaten beruht, ist die Vegetation in den CMIP-Modellen dem intern simulierten Klima ausgesetzt. In der *historical* Simulation, auf die wir uns stützen, werden diese klimatischen Variablen u.a. aus Beobachtungs-Zeitreihen zwischen 1850 bis 2014 in atmosphärischer Treibhausgas-Konzentration, Landnutzungsänderungen, vulkanischen Aerosolemissionen, Ozon-Konzentrationen, Stickstoffablagerungen und Änderungen in der solaren Einstrahlung hergeleitet (Guo et al., 2020). Für die historische CMIP-Simulation sind weiter unterschiedliche Ensemble-Läufe definiert, die sich jeweils in der Dauer der initialisierenden Kontrollsimulation unterscheiden. Wir bedienen uns dem Standardensemble *r1i1p1f1*, dessen Modelle im 600. Jahr der Kontrollsimulation starten (Eyring et al., 2016). Mehrere CMIP-ESMs stützen sich zur Simulierung des terrestrischen Kohlenstoffkreislaufs auf DGVMs aus den TRENDY- und CMIP-Reihen. So integrieren MPI-ESM-1-2-Ham und MPI-ESM-1-2-LM jeweils JSBACH3.2 (TRENDY), während CESM2 und CESM2-WACCM resp. TaiESM1 und SAM0-UNICON sich auf CLM5.0 (TRENDY) resp. CLM4.0 (MsTMIP) stützen (vgl. Anhang A.2). Eine Reihe weiterer ESMs basieren auf älteren Versionen von CLM, ORCHIDEE und CABLE (WCRP-CMIP CMIP6 CVs team, 2025). Die Daten wurden am 11.06.2025 via dem DKRZ-Node des ESGF-Metagrid (<https://esgf-metagrid.cloud.dkrz.de/search>) bezogen.

3.2.3 MsTMIP

MsTMIP versammelt mehrere Landmodelle, die bei einem standardisierten Spin-Up und nach einem geteilten Simulationsprotokoll mit Beobachtungsdaten in Klima, Landnutzungsänderungen, atmosphärischer CO₂-Konzentration und Stickstoff-Verfügbarkeit über die Periode 1901 – 2010 angetrieben werden. In dieser Analyse bauen wir auf die Outputs der SG1- und SG3-Simulationen. Während in der SG1-Simulation Landnutzung, atmo-

sphärische CO₂-Konzentration und Stickstoffverfügbarkeit konstant gehalten sind und lediglich Klimavariablen über die Simulationsperiode variieren, geht die SG3-Simulation bloss noch von konstanter Stickstoff-Deposition aus (Huntzinger et al., 2013). Uns liegen Daten für 13 Modelle in SG1 resp. zwölf Modelle in SG3 vor. Diese wurden am 03.03.2025 unter <https://doi.org/10.3334/ORNLDAAAC/1225> bezogen.

3.2.4 FLUXCOM

Der FLUXCOM-Ansatz basiert auf der Skalierung global verteilter Schätzungen von lokalen Kohlenstoffflüssen aus Eddy-Kovarianz-Messungen. Innerhalb des FLUXCOM-Projekts werden zwei unterschiedliche Ansätze zur Skalierung der Eddy-Kovarianz-Messungen verfolgt: Der RS-Ansatz und der RS+METEO-Ansatz. Beide Methoden basieren auf Maching-Learing-Verfahren, unterscheiden sich jedoch grundlegend in den verwendeten Eingangsdaten und damit auch in ihren Anwendungsbereichen und Limitationen. So stützt sich der RS-Ansatz ausschließlich auf satellitengestützte Beobachtungen, dies bspw. für Vegetationsindizes, Oberflächentemperatur, Albedo und Strahlungsdaten. Da keine meteorologischen Reanalysedaten einbezogen werden, spiegelt dieser Ansatz primär vegetationsphysiologische Zustände und strukturelle Eigenschaften der Landoberfläche wider. Im Gegensatz dazu integriert der RS+-METEO-Ansatz zusätzlich zu den Fernerkundungsdaten auch meteorologische Reanalysedaten. Damit können dynamische Prozesse wie klimatisch induzierte Variationen in GPP, Respirationsprozesse und latente Wärmeflüsse abgebildet werden (Jung et al., 2020). Schliesslich werden Outputs für drei unterschiedliche ML-Algorithmen vorgelegt, wobei wir uns hier auf den Mittelwert über die drei Ansätze stützen. Die Daten wurden am 06.03.2025 via <https://www.bgc-jena.mpg.de/geodb/projects/FileDetails.php> bezogen.

3.2.5 P-Model

Das P-Modell (Prentice et al., 2014; Wang et al., 2017) ist ein optimalitätsbasiertes, semi-mechanistisches Modell, das einen Mittelweg zwischen klassischen RS-Modellen und komplexeren prozessbasierten Modellen vorschlägt. So stützt es sich zwar gleich den einschlägigen RS-Modellen auf die LUE-Gleichung, parametrisiert LUE jedoch nicht empirisch, sondern leitet dieses nach blattphysiologischen Prozessen her. Das LUE-Modell wurde entwickelt, um zentrale Funktionen der Pflanzenphysiologie, insbesondere Photo-

synthese und stomatäre Regulation, mit möglichst geringer Parametrisierung zu schätzen. Dabei basiert es auf dem Prinzip der ökophysiologischen Optimierung, wonach Pflanzen ihren Kohlenstoff- und Wasserhaushalt unter gegebenen Umweltbedingungen so regulieren, dass ihr Ertrag maximiert bzw. der Ressourceneinsatz minimiert wird (vgl. Kapitel 2.2). Wir stützen uns hier auf eine Weiterentwicklung des P-Modells nach Stocker et al. (2019), das zusätzlich Funktionen zur Abbildung von Bodenfeuchte integriert und das deutlich Überschätzungen von GPP im Kontext von Dürre-Ereignissen korrigiert. Die Daten wurden am 07.03.2025 via <https://zenodo.org/records/1423484> bezogen.

4 Ergebnisse

4.1 Jährliche Absolutwerte, Trends und Variationskoeffizienten

Im folgenden diskutieren wir die Verteilungen von Absolutwerten, Trends und Variationskoeffizienten. Wir tun dies sowohl innerhalb der einzelnen Ensemble-Gruppen als auch simulationsübergreifend. Zur Einsicht weiterführender Graphen, durch die sich individuelle Modellschätzungen nachvollziehen lassen, verweisen wir auf den *figures*-Ordner des im Daten-und-Codeverfügbarkeits-Statement verlinkten Git-Hub-Repositoriums.

4.1.1 TRENDY

Die TRENDY-GPP-Jahresreihen zeigen sowohl für die Wertebereiche, über die sich die Verteilungen erstrecken, als auch in Hinblick auf die zeitlichen Trends und die Schwankungen um diese starke Unterschiede zwischen den Modellen. Werte in einem mittleren Bereich der Ensembleverteilung (Min. p25 – Max. p75) zwischen $110 - 145 \text{ Pg C yr}^{-1}$ versammeln CLASSIC, OCN, LPJws, JSBACH, SDGVM, LPX-Bern, VISIT, CABLE-POP und ORCHIDEE sowie IBIS und ISAM. Der Median des Ensemble-Interquartilsabstand beträgt $37.2 \text{ Pg C yr}^{-1}$. Am unteren Ende der Ensembleverteilung kommen die Zeitreihen von EDv3 und LPJ-GUESS zu liegen, dies mit Werten zwischen $90 - 110 \text{ Pg C yr}^{-1}$. CLM5.0 und LPJmL schätzen Verteilungen zwischen $155 - 180 \text{ Pg C yr}^{-1}$ und kommen damit über alle Jahre der Untersuchungsperiode oberhalb des Interquartilbereichs zu liegen. Mit Abstand die höchsten Werte zeigen sich für die Zeitreihen von JULES und E3SM – sie führen Verteilungen zwischen $175 - 203 \text{ Pg C yr}^{-1}$ an. Wir beobachten für alle Modelle einen positiven linearen Trend. Dieser liegt im Ensemble-Median um $0.42 \text{ Pg C yr}^{-1}$ [p25 = $0.38 \text{ Pg C yr}^{-1}$, p75 = $0.46 \text{ Pg C yr}^{-1}$]. Dabei modellieren E3SM, JSBACH und JULES mit Werten um $0.55 \text{ Pg C yr}^{-1}$ die höchsten mittleren jährlichen Zunahmen, ISAM mit einem Wert von $0.25 \text{ Pg C yr}^{-1}$ die Geringste. Der Variationskoeffizient beträgt im Median $0.017 \text{ Pg C yr}^{-1}$ [p25 = $0.013 \text{ Pg C yr}^{-1}$, p75 = $0.022 \text{ Pg C yr}^{-1}$]. Die höchsten Werte beobachten wir dabei für JSBACH ($0.043 \text{ Pg C yr}^{-1}$) und JULES ($0.037 \text{ Pg C yr}^{-1}$). Der mit Abstand geringste Variationskoeffizient liegt mit $0.004 \text{ Pg C yr}^{-1}$ für ISAM vor. Tiefe Werte zeigen sich auch für EDv3 ($0.011 \text{ Pg C yr}^{-1}$) und IBIS ($0.012 \text{ Pg C yr}^{-1}$).

Mit Blick auf die NBP-Zeitreihen versammelt die Median-Verteilung Werte zwischen $-0.8 - 2.5 \text{ Pg C yr}^{-1}$, dies um einen mittleren Bereich (Min. p25 – Max. p75) zwischen

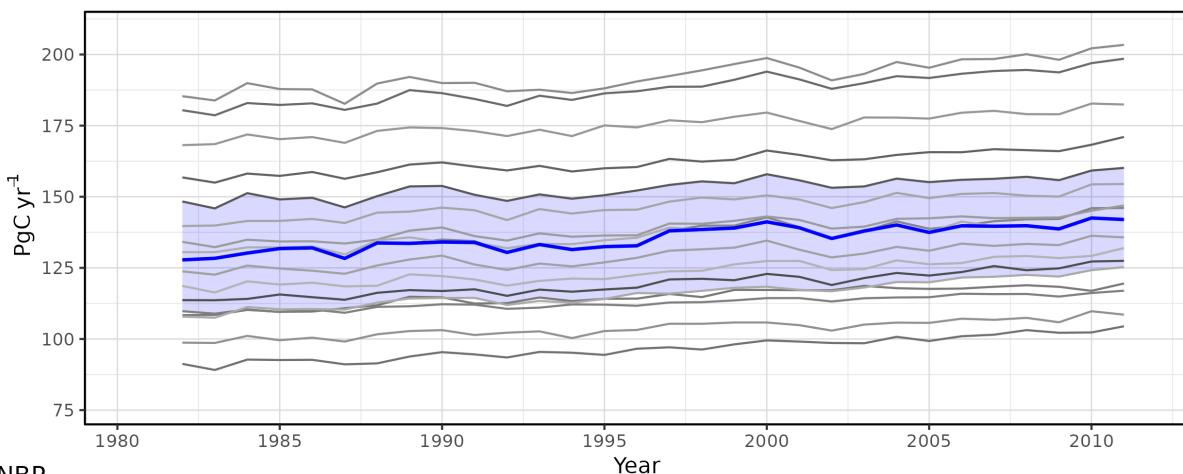
$-2 - 3 \text{ Pg C yr}^{-1}$. Die höchsten Einjahres-Maximalwerte schätzen E3SM und CLASSIC bei 4.5 Pg C yr^{-1} . Auch in NBP beobachten wir für alle Modelle positive lineare Trends, dies um einen Median von $0.05 \text{ Pg C yr}^{-1}$ [$\text{p25} = 0.027 \text{ Pg C yr}^{-1}$, $\text{p75} = 0.06 \text{ Pg C yr}^{-1}$]. Die geringsten mittleren Zunahmen zeigen nun LPJ-GUESS ($0.003 \text{ Pg C yr}^{-1}$) und LPJmL ($0.007 \text{ Pg C yr}^{-1}$) mit Werten, die 7.2 resp. 3.3 mal geringer ausfallen als jener von ISAM, der drittgeringsten Trendstärke, und damit innerhalb der Ensemble-Verteilung stark nach unten ausreissen. Die höchsten Trendstärke zeigen umgekehrt LPJwsl ($0.11 \text{ Pg C yr}^{-1}$) und SDGVM ($0.09 \text{ Pg C yr}^{-1}$), deren Trendstärken in GPP in der unteren Verteilungshälfte lagen. Der Variationskoeffizient beträgt im Median $0.006 \text{ Pg C yr}^{-1}$ [$\text{p25} = 0.003 \text{ Pg C yr}^{-1}$, $\text{p75} = 0.007 \text{ Pg C yr}^{-1}$]. Die geringsten Werte liegen dabei wie bereits bei den Trendstärken für LPJmL ($5.9 \times 10^{-5} \text{ Pg C yr}^{-1}$) und LPJ-GUESS ($7.9 \times 10^{-5} \text{ Pg C yr}^{-1}$) vor. Die höchsten Variationskoeffizienten zeigen E3SM ($0.023 \text{ Pg C yr}^{-1}$) und CLASSIC ($0.018 \text{ Pg C yr}^{-1}$). Mit einem Spearman-Korrelationskoeffizient (ρ_s) von 0.66 halten wir einen deutlich ausgebildeten positiv-montonen Zusammenhang zwischen den Werten in GPP und NBP fest. Stark negative Rangdifferenzen ($\text{Rank GPP} - \text{Rank NBP} < 0$) zeigen JSBACH (-8), JULES, LPX-Bern und OCN (jeweils -3). Positive Rangdifferenzen liegen u.a. für IBIS, E3SM (beide $+5$) und LPJwsl ($+3$) vor.

4.1.2 CMIP

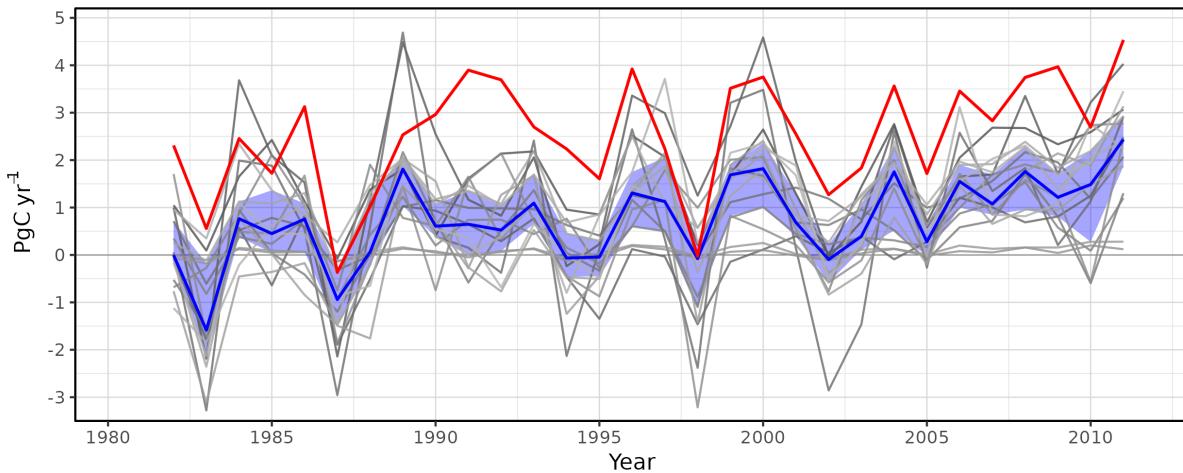
Die CMIP-Modelle schätzen in GPP Medianwerte zwischen $134 - 150 \text{ Pg C yr}^{-1}$. Werte in einem mittleren Bereich (Min. p25 – Max. p75) zwischen $126 - 159 \text{ Pg C yr}^{-1}$ versammeln NorESM2-LM, SAM0-UNICON, GFDL-ESM4, MPI-ESM-1-2-HAM, IPSL-CM6A-LR, TaiESM1, IPSL-CM6A-LR-INCA, MPI-ESM-1-2-LR, NORESM2-MM, EC-Earth3-Veg, EC-Earth3-CC, EC-Earth3-Veg-LR, CESM2 und CESM2-WACCM. Am unteren Ende der Verteilung liegen CMCC-CM2-SR5, CMCC-ESM2 und ACCESS-ESM1-5, dies mit Werten um 120 Pg C yr^{-1} . INM-CM4-8 und INMCM5-0 schätzen Mediane von 155 Pg C yr^{-1} und 159 Pg C yr^{-1} , wobei sämtliche Jahreswerte oberhalb des jeweiligen 75%-Perzentil zu liegen kommen. Mit Werteverteilungen zwischen $197 - 219 \text{ Pg C yr}^{-1}$ zeigen CanESM5 und CanESM5-1 die mit Abstand höchsten Jahresabsolutwerte. In Hinblick auf die linearen Trends stellen wir wiederum für alle Modelle positive Werte fest, dies um einen Median von $0.39 \text{ Pg C yr}^{-1}$ [$\text{p25} = 0.36 \text{ Pg C yr}^{-1}$, $\text{p75} = 0.54 \text{ Pg C yr}^{-1}$]. ACCESS-ESM1-5, GFDL-ESM4 und SAM-UNICON verzeichnen mit Werten $< 0.3 \text{ Pg C yr}^{-1}$ die gering-

Verlauf jährlicher Absolutwerte

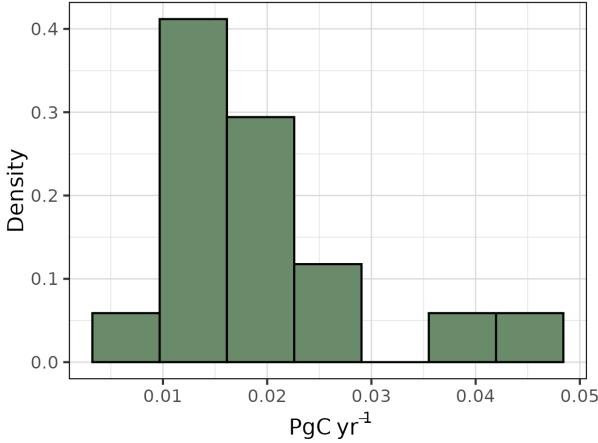
GPP



NBP

**Verteilung Variationskoeffizienten**

GPP



NBP

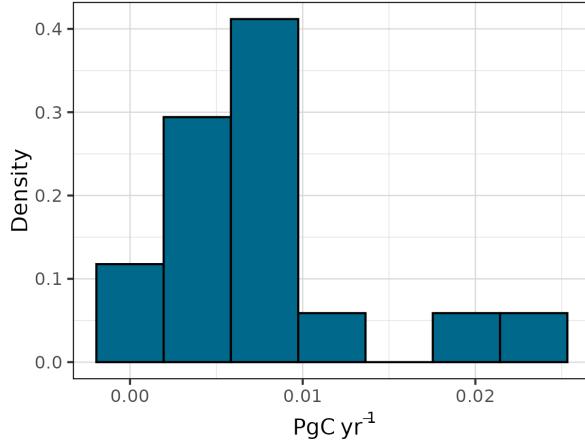


Abbildung 1: Geschätzte jährliche Absolutwerte zwischen 1982-2011 für die Outputs der TRENDY-Simulation. Graue Linien markieren die individuellen Modellverläufe, während die blaue Linie jeweils den Verlauf des Ensemble-Medians zeigt. Die blaue Fläche markiert den Interquartilbereich. Darunter zeigen wir die ensembleweite Werteverteilung der Variationskoeffizienten. Die Y-Achse folgt dabei einer relativen Skalierung und gibt den Anteil der in den Wertebereich des jeweiligen Bins fallenden Modelle am gesamten Ensemble an.

ten Trendstärken. Mit Werten $> 0.7 \text{ Pg C yr}^{-1}$ verzeichnen MPI-ESM-1-2-HAM und INM-CM4-8 die höchsten Trendstärken. Der Median der Variationskoeffizienten liegt bei $0.024 \text{ Pg C yr}^{-1}$ [$\text{p25} = 0.019 \text{ Pg C yr}^{-1}$, $\text{p75} = 0.030 \text{ Pg C yr}^{-1}$]. Den mit Abstand höchsten Wert beobachten wir dabei für MPI-ESM-1-2-LR ($0.088 \text{ Pg C yr}^{-1}$), den Geringsten für CanESM5-1 ($0.011 \text{ Pg C yr}^{-1}$).

Mit Blick auf die NBP-Zeitreihen schätzt die Median-Verteilung das terrestrische Ökosystem über sämtliche Jahre der Untersuchungsperiode als Nettosenke, dies mit Werten zwischen $0.28 - 2.30 \text{ Pg C yr}^{-1}$. Die Mehrzahl der Modelle bildet Verteilungen mit Werten zwischen $-0.85 - 3.57 \text{ Pg C yr}^{-1}$ ab. Die tiefsten Einjahreswerte schätzen CanESM5 ($-5.26 \text{ Pg C yr}^{-1}$) und EC-Earth3-Veg-LR ($-4.94 \text{ Pg C yr}^{-1}$). Keines der Modelle setzt sich klar nach unten ab. Vielmehr scheinen die Zeitreihen weniger synchron zu verlaufen als jene der TRENDY-Reihe, so dass Modelle, die im einen Jahr Werte im oberen Bereich der Ensemble-Verteilung schätzten, für ein anderes Jahr die tiefsten Werte schätzen. Die einzigen Modelle, für die wir Verteilungen beobachten, die sich systematisch vom oben angeführten mittleren Wertebereich abzuheben scheinen, sind INM-CM4-8 und INM-CM5-0. Sie zeigen Medianwerte $> 4.5 \text{ Pg C yr}^{-1}$ und schätzen die höchsten Einjahreswerte von $13.07 \text{ Pg C yr}^{-1}$ resp. $11.07 \text{ Pg C yr}^{-1}$. In Hinblick auf die linearen Trends liegt ein Median von $0.02 \text{ Pg C yr}^{-1}$ vor [$\text{p25} = 0.004 \text{ Pg C yr}^{-1}$, $\text{p75} = 0.035 \text{ Pg C yr}^{-1}$]. Für INM-CM5-0 ($-0.060 \text{ Pg C yr}^{-1}$), SAM-UNICON ($-0.035 \text{ Pg C yr}^{-1}$), ACCESS-ESM1-5 ($-0.025 \text{ Pg C yr}^{-1}$) und CanESM5 ($-0.021 \text{ Pg C yr}^{-1}$) stellen wir negative Trendstärken fest. MPI-ESM-1-2-HAM schätzt wie bereits in GPP den höchsten mittleren linearen Anstieg; gemeinsam mit CanESM5-1 zeigt das Modell eine Trendstärke von $> 0.06 \text{ Pg C yr}^{-1}$. Der Median der Variationskoeffizienten liegt bei $0.012 \text{ Pg C yr}^{-1}$ [$\text{p25} = 0.009 \text{ Pg C yr}^{-1}$, $\text{p75} = 0.021 \text{ Pg C yr}^{-1}$]. Den höchsten Wert beobachten wir für GFDL-ESM4 ($0.034 \text{ Pg C yr}^{-1}$), den Geringsten für CESM2-WACCM ($0.004 \text{ Pg C yr}^{-1}$). Bei $\rho_s = 0.46$ halten wir einen moderat ausgebildeten positiv-monotonen Zusammenhang zwischen den Werten in GPP und NBP fest. Stark negative Rangdifferenzen liegen für MPI-ESM-1-2-LR (-13), NorESM2-MM (-10) und MPI-ESM-1-2-HAM (-9) vor. Positive Rangdifferenzen liegen u.a. für EC-Earth3-Veg-LR, CanESM5 (jeweils $+10$) sowie für TaiESM1 und INM-CM5-0 (jeweils $+7$) vor.

Während JSBACH3.2, das als Landkomponente in den MPI-ESM-1-2-Modellen herangezogen wird, für GPP in den Absolutwerten jeweils in der CMIP-Simulation höhere

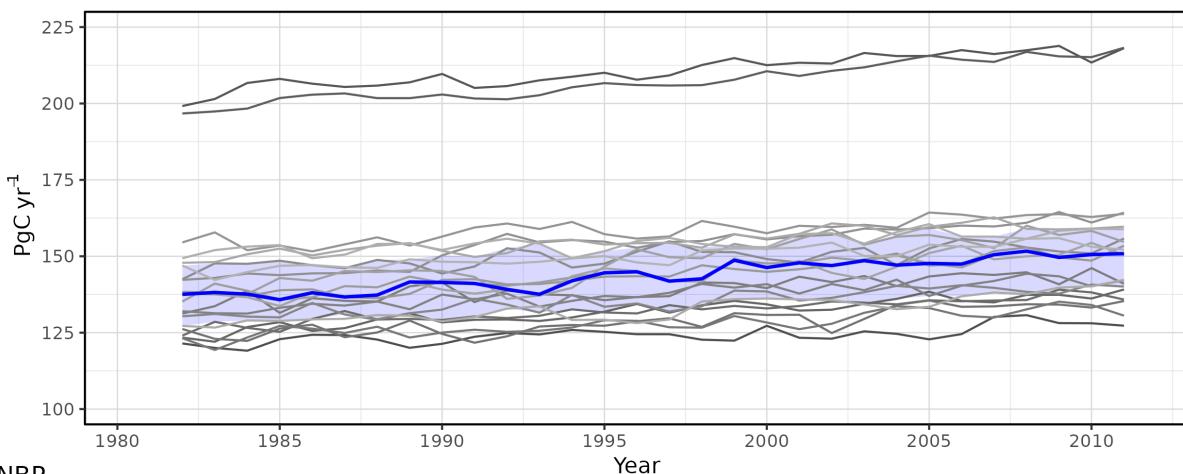
Medianwerte zeigt, liegt für NBP der Medianwert des TRENDY-Outputs über jenen der CMIP-ESMs. Mit Blick auf die Trendstärke beobachten wir in GPP höhere Werte für beide CMIP-Simulationen, in NBP liegt der mittlere lineare Anstieg des TRENDY-Outputs zwischen den CMIP-Werten. Schliesslich zeigt JSBACH in GPP einen praktisch identischen Variationskoeffizienten im TRENDY-Output ggü. jenem aus MPI-ESM-1-2-LR, gleichzeitig fällt der Variationskoeffizient aus MPI-ESM-1-2-HAM etwa doppelt so hoch aus. In NBP beobachten wir deutlich höhere Variationskoeffizienten für die CMIP-Simulationen. Ein gegensätzliches Bild zeigt sich nun für CLM5.0, auf das sich die CESM2-Modelle stützen. So liegt in den GPP-Absolutwerten der Median der TRENDY-Simulation höher, während in NBP die CMIP-Outputs einen höheren Median aufweisen. In Hinblick auf die Trendstärke liegt der Wert der TRENDY-Simulation in GPP zwischen jenen der CMIP-Outputs. In NBP zeigt das Modell im TRENDY-Lauf einen deutlich stärkeren mittleren linearen Anstieg als in der CMIP-Simulation. Für den Variationskoeffizienten beobachten wir in GPP, dass der TRENDY-Wert zwischen jenen der CMIP-Simulation liegt, während für NBP der TRENDY-Output den höchsten Wert zeigt.

4.1.3 MsTMIP SG1

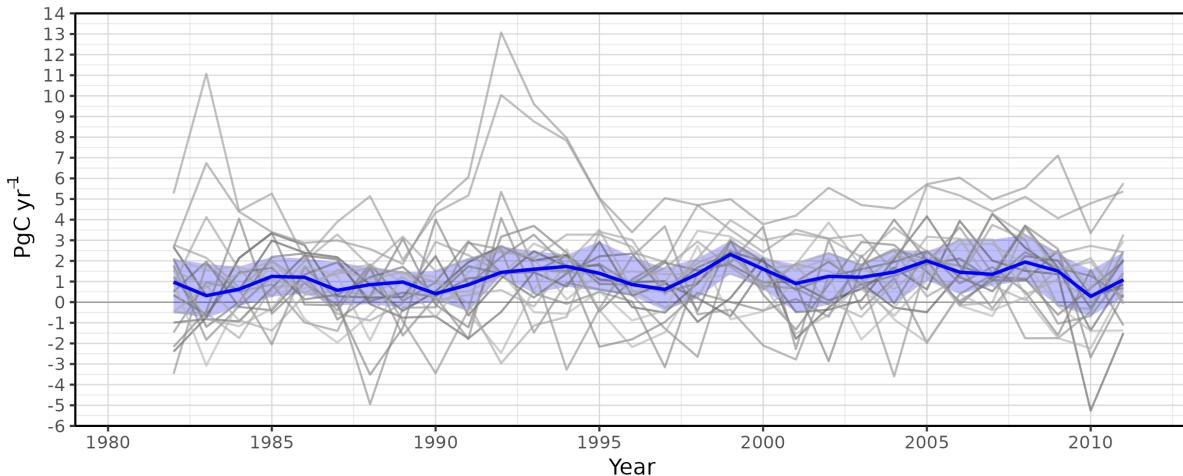
Die MsTMIP-Modelle schätzen in der SG1-Simulation Medianwerte zwischen $106 - 114 \text{ Pg C yr}^{-1}$. In einen mittleren Bereich zwischen $94 - 142 \text{ Pg C yr}^{-1}$ fallen BIOME-BGC, LPJ-wsl, CLM4, SiBCASA, VEGAS2.1, VISIT2.1, CLM4VIC und ORCHIDEE-LSCE. CLASS-CTEM-N führt mit Werten zwischen $66 - 71 \text{ Pg C yr}^{-1}$ die Verteilung im tiefsten Wertebereich des Ensembles an. Tiefe Werte zeigen sich auch für TEM6, dies wiederum bei einer eng gestreuten Verteilung zwischen $82 - 86 \text{ Pg C yr}^{-1}$. Die Zeitreihe von SiB3 verläuft mit Werten zwischen $146 - 150 \text{ Pg C yr}^{-1}$ über die gesamte Untersuchungsperiode oberhalb der 75%-Perzentil-Linie. GTEC versammelt Werte zwischen $165 - 170 \text{ Pg C yr}^{-1}$, schätzt damit die mit Abstand höchsten Werte. Wir beobachten wiederum für alle Modelle positive lineare Trends. Die Median-Trendstärke fällt mit $0.11 \text{ Pg C yr}^{-1}$ etwa 3.5 mal geringer aus als jene um 0.4 Pg C yr^{-1} , wie wir sie für die TRENDY- und CMIP-Modelle beobachteten, wobei sich eine deutlich engere Verteilung der Trendstärken zeigt [$\text{p25} = 0.10 \text{ Pg C yr}^{-1}$, $\text{p75} = 0.17 \text{ Pg C yr}^{-1}$]. Mit Blick auf die Verteilung der Variationskoeffizienten beobachten wir einen Median von $0.013 \text{ Pg C yr}^{-1}$ [$\text{p25} = 0.004 \text{ Pg C yr}^{-1}$, $\text{p75} = 0.016 \text{ Pg C yr}^{-1}$]. Die Verteilung erstreckt sich über einen tieferen Wertebereich als jene der TRENDY- und

Verlauf jährlicher Absolutwerte

GPP

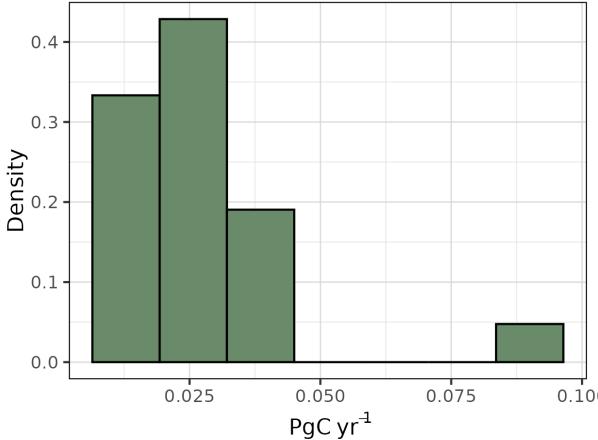


NBP



Verteilung Variationskoeffizienten

GPP



NBP

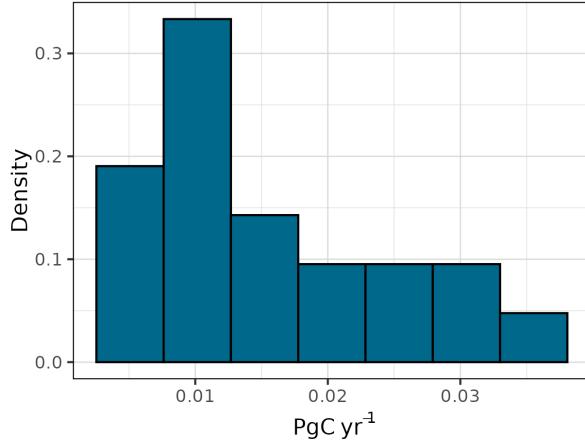


Abbildung 2: Geschätzte jährliche Absolutwerte zwischen 1982-2011 für die Outputs der CMIP-Simulation. Graue Linien markieren die individuellen Modellverläufe, während die blaue Linie jeweils den Verlauf des Ensemble-Medians zeigt. Die blaue Fläche markiert den Interquartilbereich. Darunter zeigen wir die ensembleweite Werteverteilung der Variationskoeffizienten. Die Y-Achse folgt dabei einer relativen Skalierung und gibt den Anteil der in den Wertebereich des jeweiligen Bins fallenden Modelle am gesamten Ensemble an.

CMIP-Modelle.

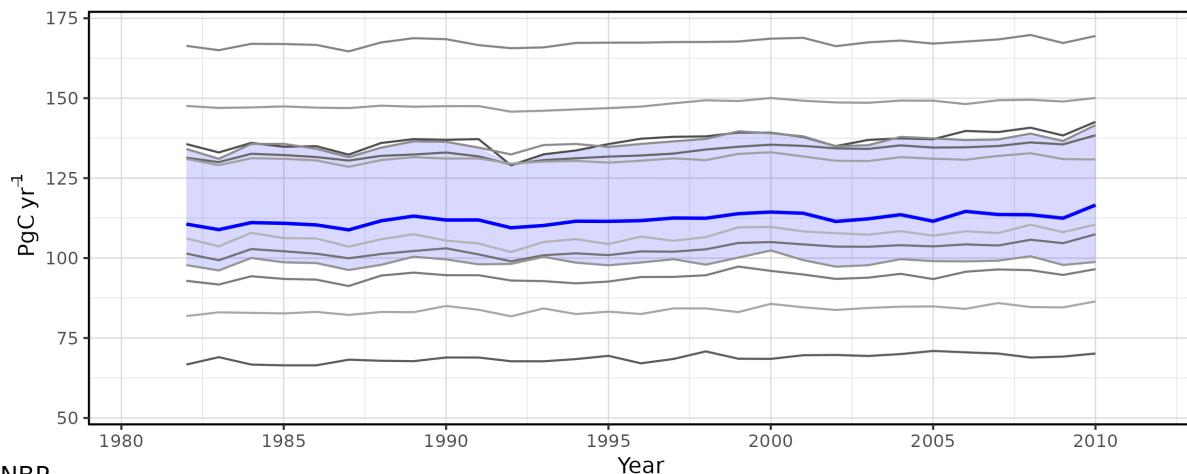
Mit Blick auf NBP liegt eine Medianverteilung mit Werten zwischen $-0.8 - 1.6 \text{ Pg C yr}^{-1}$ vor. In einen mittleren Bereich zwischen $-1.45 - 2.9 \text{ Pg C yr}^{-1}$ fallen GTEC, ORCHIDEE-LSCE, SiBCASA, SiB3, TEM6, VISIT, DLEM, LPJ-wsl, CLM4 und BIOME-BGC. GTEC und LPJ-wsl zeigen mit 0.7 Pg C yr^{-1} resp. $1.02 \text{ Pg C yr}^{-1}$ die höchsten Medianwerte und mit Werten um 3.7 Pg C yr^{-1} die höchsten Einjahreswerte. Umgekehrt zeigt CLASS-CTEM-N mit $-1.8 \text{ Pg C yr}^{-1}$ den tiefsten Medianwert und mit $-2.9 \text{ Pg C yr}^{-1}$ den tiefsten Einjahreswert. Die MsTMIP-Modelle zeigen in der SG1-Simulation – im Gegensatz zu den TRENDY- und CMIP-Ensembles – einen im Median negativen linearen Trend von $-0.014 \text{ Pg C yr}^{-1}$ [$\text{p25} = -0.029 \text{ Pg C yr}^{-1}$, $\text{p75} = 0.006 \text{ Pg C yr}^{-1}$]. In Hinblick auf die Verteilung der Variationskoeffizienten versammelt diese Werte um den Median von $0.005 \text{ Pg C yr}^{-1}$ [$\text{p25} = 0.004 \text{ Pg C yr}^{-1}$, $\text{p75} = 0.01 \text{ Pg C yr}^{-1}$]. Dieser fällt damit geringer aus als bei den bisher diskutierten Gruppen. Höhere Variationskoeffizienten in GPP scheinen sich nur bedingt in höhere Variationskoeffizienten in NBP zu übersetzen. So liegt ein geringer Rang-Korrelationskoeffizient von $\rho_s = 0.31$ vor. Hohe absolute Rangdifferenzen liegen für BIOME-BGC (-9), GTEC (+10) und TEM6 (+5) vor.

4.1.4 MSTMIP SG3

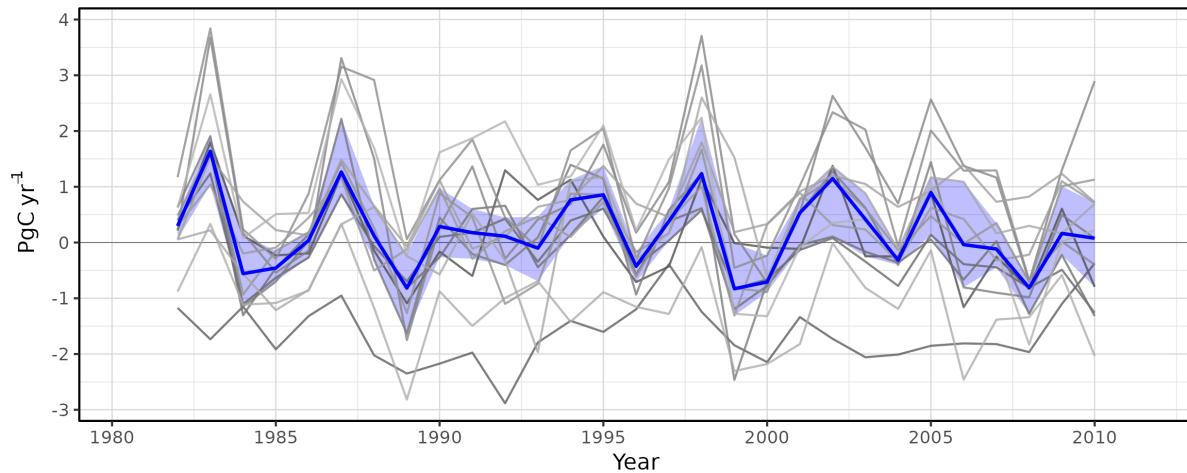
Die Zeitreihen der MsTMIP-Modelle in der SG3-Simulation versammeln Medianwerte zwischen $113 - 125 \text{ Pg C yr}^{-1}$. Werte in einem mittleren Bereich zwischen $99 - 156 \text{ Pg C yr}^{-1}$ versammeln LPJ-wsl, CLM4, VISIT, VEGAS2.1, ORCHIDEE, CLASS-CTEM-N und CLM4VIC. Bei einem Median von 102 Pg C yr^{-1} kommen die Werte von DLEM für sämtliche Jahre der Untersuchungsperiode unterhalb der 25%-Perzentil-Werte zu liegen. Schliesslich schätzt TEM6 die Verteilung mit den tiefsten Werten. Diese versammelt Schätzungen zwischen $87 - 95 \text{ Pg C yr}^{-1}$. Oberhalb der 75%-Perzentil-Linie kommen die Zeitreihen von SiB3 und SiBCASA zu liegen. Sie führen Werte zwischen $161 - 178 \text{ Pg C yr}^{-1}$ an. Die höchsten Werte beobachten wir – wie bereits im Output der SG1-Simulation – für GTEC. Dieses versammelt Werte zwischen $181 - 197 \text{ Pg C yr}^{-1}$. Die Modelle zeigen im Ensemble-Median einen linearen Trend von $0.44 \text{ Pg C yr}^{-1}$ [$\text{p25} = 0.34 \text{ Pg C yr}^{-1}$, $\text{p75} = 0.5 \text{ Pg C yr}^{-1}$]. Dieser liegt nahe bei jenen der TRENDY- und CMIP-Outputs, fällt gleichzeitig vier mal höher aus als der lineare Trend, den die Modelle im Median in der SG1-Simulation zeigen. Mit Blick auf die Verteilung der Variationskoeffizienten zeigt sich

Verlauf jährlicher Absolutwerte

GPP

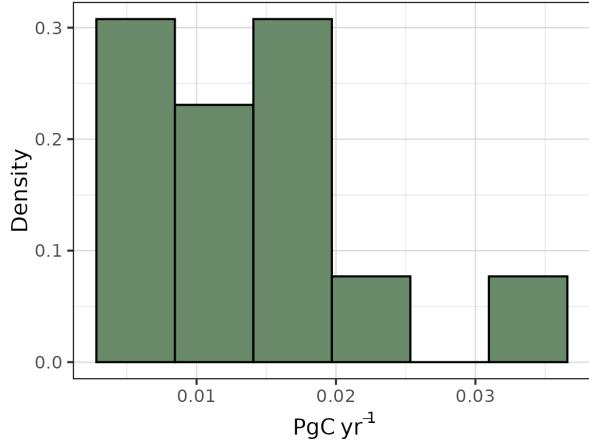


NBP



Verteilung Variationskoeffizienten

GPP



NBP

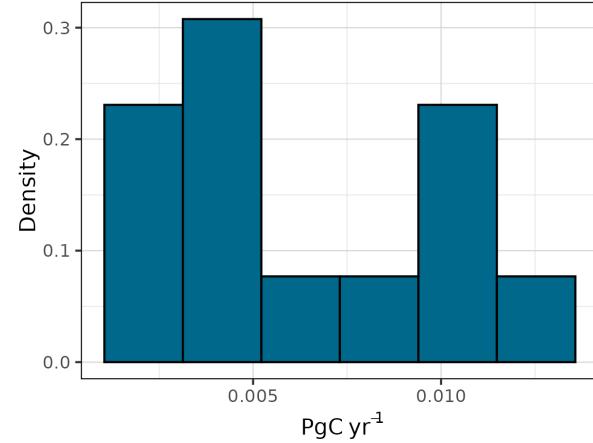


Abbildung 3: Geschätzte jährliche Absolutwerte zwischen 1982-2010 für die Outputs der MsTMIP-SG1-Simulation. Graue Linien markieren die individuellen Modellverläufe, während die blaue Linie jeweils den Verlauf des Ensemble-Medians zeigt. Die blaue Fläche markiert den Interquartilbereich. Darunter zeigen wir die ensembleweite Werteverteilung der Variationskoeffizienten. Die Y-Achse folgt dabei einer relativen Skalierung und gibt den Anteil der in den Wertebereich des jeweiligen Bins fallenden Modelle am gesamten Ensemble an.

ein Median von $0.015 \text{ Pg C yr}^{-1}$ [$\text{p25} = 0.012 \text{ Pg C yr}^{-1}$, $\text{p75} = 0.016 \text{ Pg C yr}^{-1}$]. Dieser fällt damit zwischen die korrespondierenden Werte von MsTMIP-SG1 und TRENDY.

Mit Blick auf NBP liegt eine Medianverteilung mit Werten zwischen $-2.57 - 0.88 \text{ Pg C yr}^{-1}$ vor. Die Modelle scheinen damit systematisch tiefere Absolutwerte als in der SG1-Simulation und ggü. den TRENDY- und CMIP-Ensembles zu schätzen. Werte über einen mittleren Bereich zwischen $-5.36 - 2.03 \text{ Pg C yr}^{-1}$ versammeln die Verteilungen von DLEM, CLM4, GTEC, CLM4VIC, ORCHIDEE-LSCE, VEGAS, LPJ-wsl und VISIT. Die Werte von SiBCASA kommen über sämtliche Jahre der Beobachtungsperiode unterhalb der entsprechenden 25%-Perzentil-Werte zu liegen. Die mit Abstand tiefsten Werte zeigt – wie bereits in der SG1-Simulation – CLASS-CTEM-N; dies bei einem Median von $-7.4 \text{ Pg C yr}^{-1}$. Die Zeitreihen mit den höchsten Medianwerten versammeln CLM4 ($0.45 \text{ Pg C yr}^{-1}$) und SiB3 ($0.25 \text{ Pg C yr}^{-1}$). Die Modelle zeigen im Ensemble-Median einen linearen Trend von $-0.075 \text{ Pg C yr}^{-1}$ [$\text{p25} = -0.116 \text{ Pg C yr}^{-1}$, $\text{p75} = -0.049 \text{ Pg C yr}^{-1}$]. Dieser fällt rund 5.5 mal stärker aus als jener der der SG1-Simulation. Während die Richtung des Median-Trends wiederum entgegengesetzt zu jenen der TRENDY- und CMIP-Outputs ausfällt, liegt dessen Stärke rund 1.5 mal resp. 3.5 mal höher als bei TRENDY resp. CMIP. Mit Blick auf die Verteilung der Variationskoeffizienten zeigt sich ein Median von $0.005 \text{ Pg C yr}^{-1}$ [$\text{p25} = 0.004 \text{ Pg C yr}^{-1}$, $\text{p75} = 0.009 \text{ Pg C yr}^{-1}$]. Dieser liegt nahe beim Wert der SG1-Simulation und fällt damit wiederum halb so gross aus wie jener des CMIP-Outputs. Die Rangkorrelation zwischen den Variationskoeffizienten in GPP und NBP von $\rho_s = 0.48$ verweist auf einen moderat positiv-monotonen Zusammenhang, der ähnlich stark ausfällt wie beim CMIP-Ensemble. Die höchsten absoluten Rangdifferenzen liegen wie bereits in der SG1-Simulation für GTEC (+9) und TEM6 (+5) vor.

Während CLM4.0, das als Landkomponente in TaiESM1 und SAM0-UNICON herangezogen wird, für GPP höhere Mediane der Absolutwerte in der CMIP-Simulation schätzt, liegt für NBP der Medianwert des MsTMIP-Outputs über jenen der CMIP-ESMs. Mit Blick auf die Trendstärke beobachten wir in GPP den höchsten Wert im Rahmen der MsTMIP-Simulation, in NBP liegt der mittlere lineare Anstieg zwischen den TRENDY-Outputs, wobei SAM0-UNICON im Median einen negativen linearen Trend abbildet, während jener von TaiESM1 positiv ausfällt. Schliesslich zeigt CLM4.0 sowohl in GPP als auch in NBP einen tieferen Variationskoeffizienten im MsTMIP-Output ggü. jenen der

CMIP-Simulation.

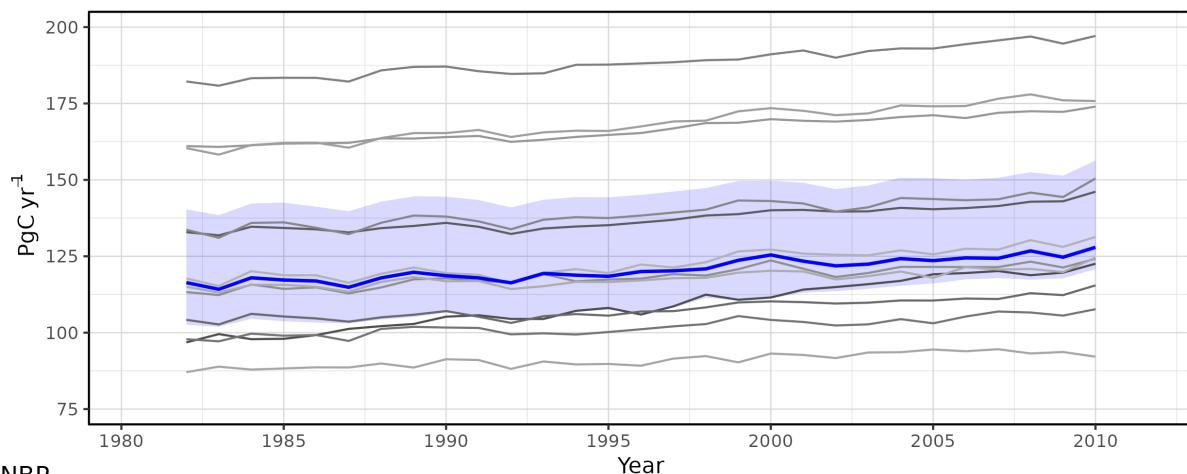
4.2 Restringiertes GPP-IAV-Interval

Die Median-Regressionslinie der Bootstrapping-Verteilung weist eine Steigung von 0.35 auf, wobei die grosse Streuung, mit der die Datenpunkte im IAV-Raum vorliegen zu grossen Unsicherheiten in dieser Schätzung führen, so dass der Konfidenzbereich Steigungswerte zwischen $0.13 - 0.77$ miteinschliesst. Dabei schlägt sich das zuvor festgestellte tiefere Verhältnis zwischen dem Variationskoeffizienten in GPP ggü. jenem in NBP für CMIP nicht in einer steileren mittleren Regressionsbeziehung nieder. So fällt die Steigung der Median-Regressionslinie für CMIP mit 0.28 zwar steiler aus als jene von MsTMIP-SG1 (0.17) und -SG3 (0.19), jedoch flacher als jene von TRENDY (0.31). Allgemein scheint keine der Ensemble-Wolken in Form und Ausrichtung stark von jenen der anderen Simulationen abzuweichen. So scheint die grosse Unsicherheit bei der Stärke des Zusammenhangs nicht primär auf systematische Unterschiede der simulierten Steigung entlang verschiedener Ensembles zurückzugehen, vielmehr zeigen die "kugeligen" Verteilungswolken, dass die Modelle innerhalb der Simulationsgruppen eine grosse Bandbreite unterschiedlich starker Zusammenhänge abbilden.

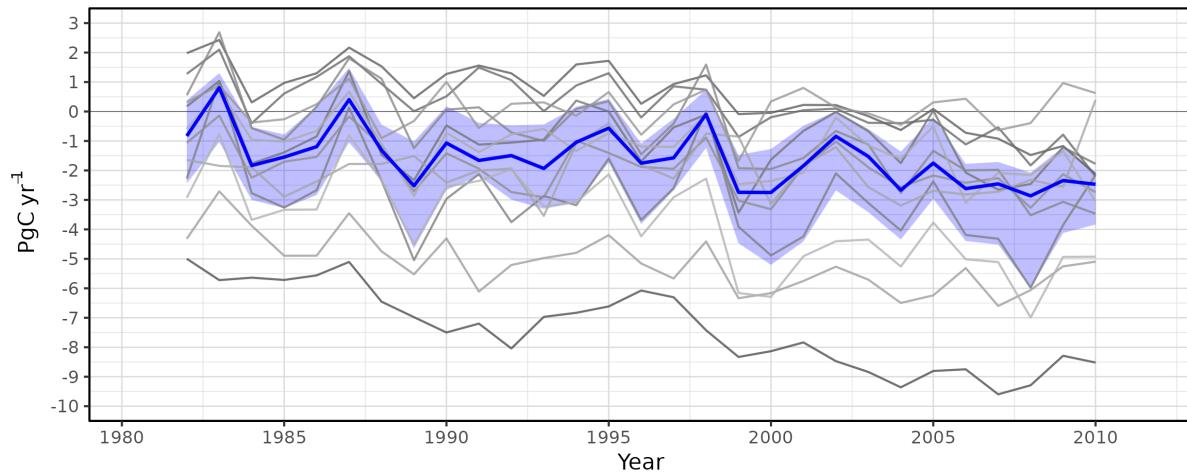
Die Varianz der trendbereinigten Absolutwerte der residualen Landsenke aus dem Global Carbon Budget beträgt $1.25 \text{ Pg C yr}^{-1}$. Aus den Schnittpunkten mit dem oberen und unteren Konfidenzband folgt ein restringierter GPP-IAV-Bereich zwischen $1.8 - 4.7 \text{ Pg C yr}^{-1}$. Dieser widerspiegelt somit den Wertebereich, über den sich die Schätzungen der Regressionsbeziehungen, die innerhalb des 95%-Konfidenzintervall der Bootstrapping-Verteilung liegen, erstrecken. Die GPP-IAV-Schätzung von FLUXCOM unterläuft dieses Intervall mit einem IAV-Wert von $0.11 \text{ Pg C yr}^{-1}$ deutlich – ein Resultat, das sich mit Blick auf die sehr geringe Streuungsbreite in den Jahresabsolutwerten bereits abgezeichnet hat und das durch Resultate vorausgehender Untersuchungen gestützt wird (Jung et al., 2009; Piao et al. (2013)). Die Schätzung des P-Model kommt mit einem Wert von 2.1 Pg C yr^{-1} innerhalb des restringierten Bereichs zu liegen.

Verlauf jährlicher Absolutwerte

GPP

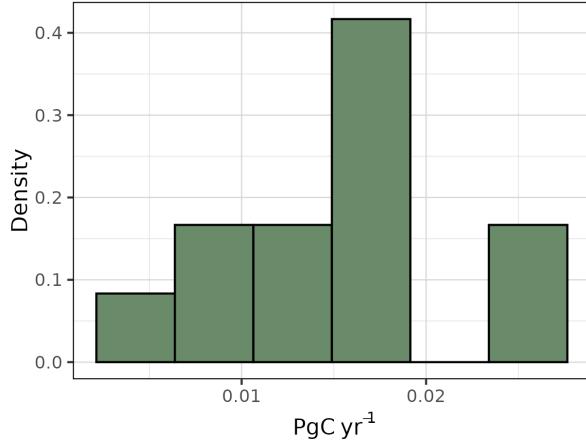


NBP



Verteilung Variationskoeffizienten

GPP



NBP

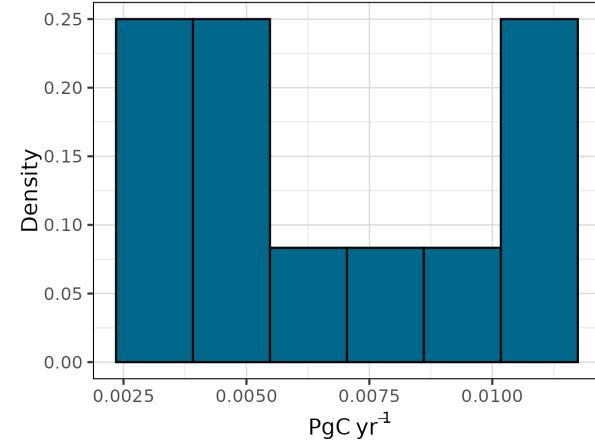


Abbildung 4: Geschätzte jährliche Absolutwerte zwischen 1982-2010 für die Outputs der MsTMIP-SG3-Simulation. Graue Linien markieren die individuellen Modellverläufe, während die blaue Linie jeweils den Verlauf des Ensemble-Medians zeigt. Die blaue Fläche markiert den Interquartilsbereich. Darunter zeigen wir die ensembleweite Werteverteilung der Variationskoeffizienten. Die Y-Achse folgt dabei einer relativen Skalierung und gibt den Anteil der in den Wertebereich des jeweiligen Bins fallenden Modelle am gesamten Ensemble an.

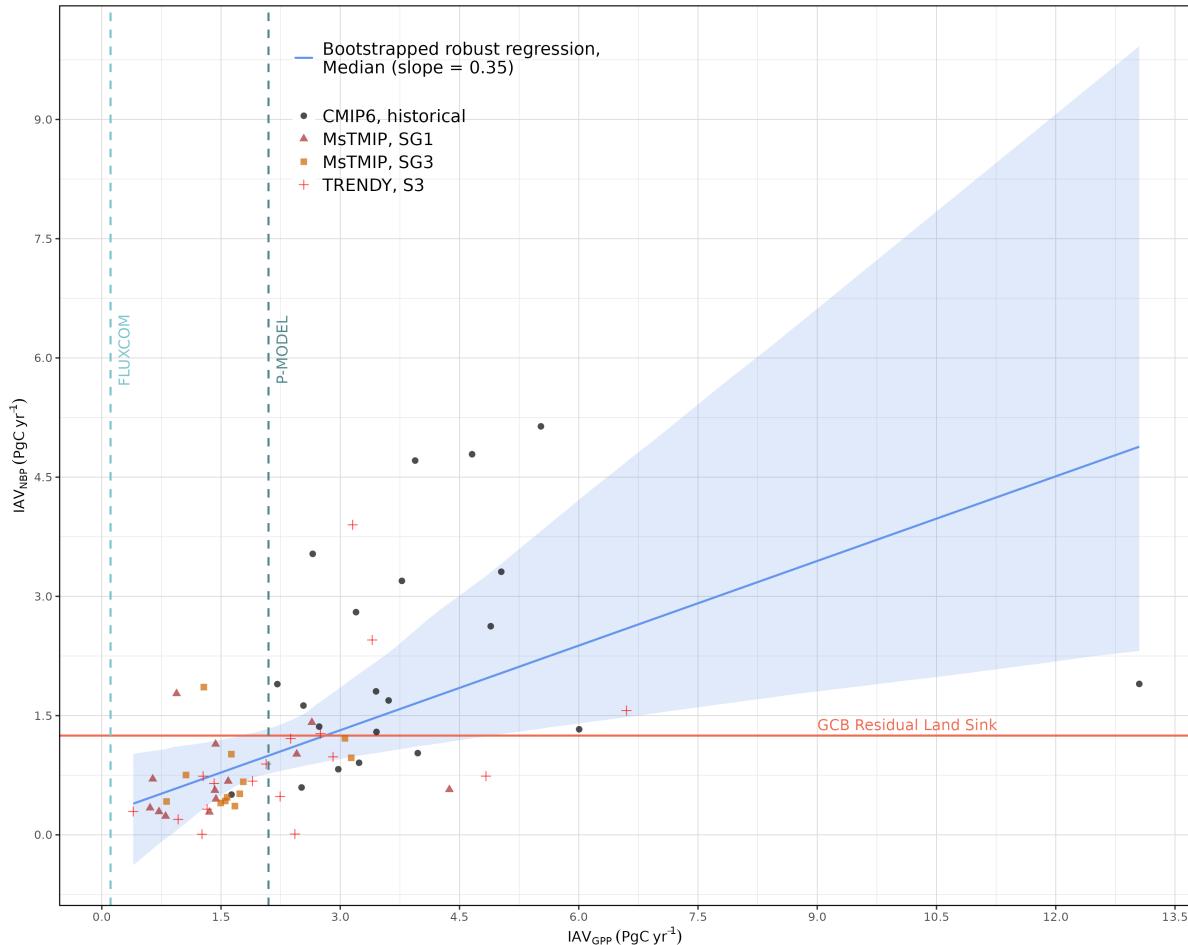


Abbildung 5: Streudiagramme der GPP- ggü. den NBP-IAV-Werten über alle berücksichtigten Modelle. Der blaue Bereich weist das 95%-Konfidenzintervall der Bootstrapping-Verteilung robuster Regressionen über die Schätzungen der TRENDY-, CMIP- und MsTMIP-SG3-Modelle aus. Die blaue Linie markiert die Median-Regression der Verteilung. Die rote Linie zeigt die IAV der residualen Landsenke aus dem Global Carbon Budget. Vertikale Linien zeigen die GPP-IAV-Schätzungen der berücksichtigten RS-Modelle.

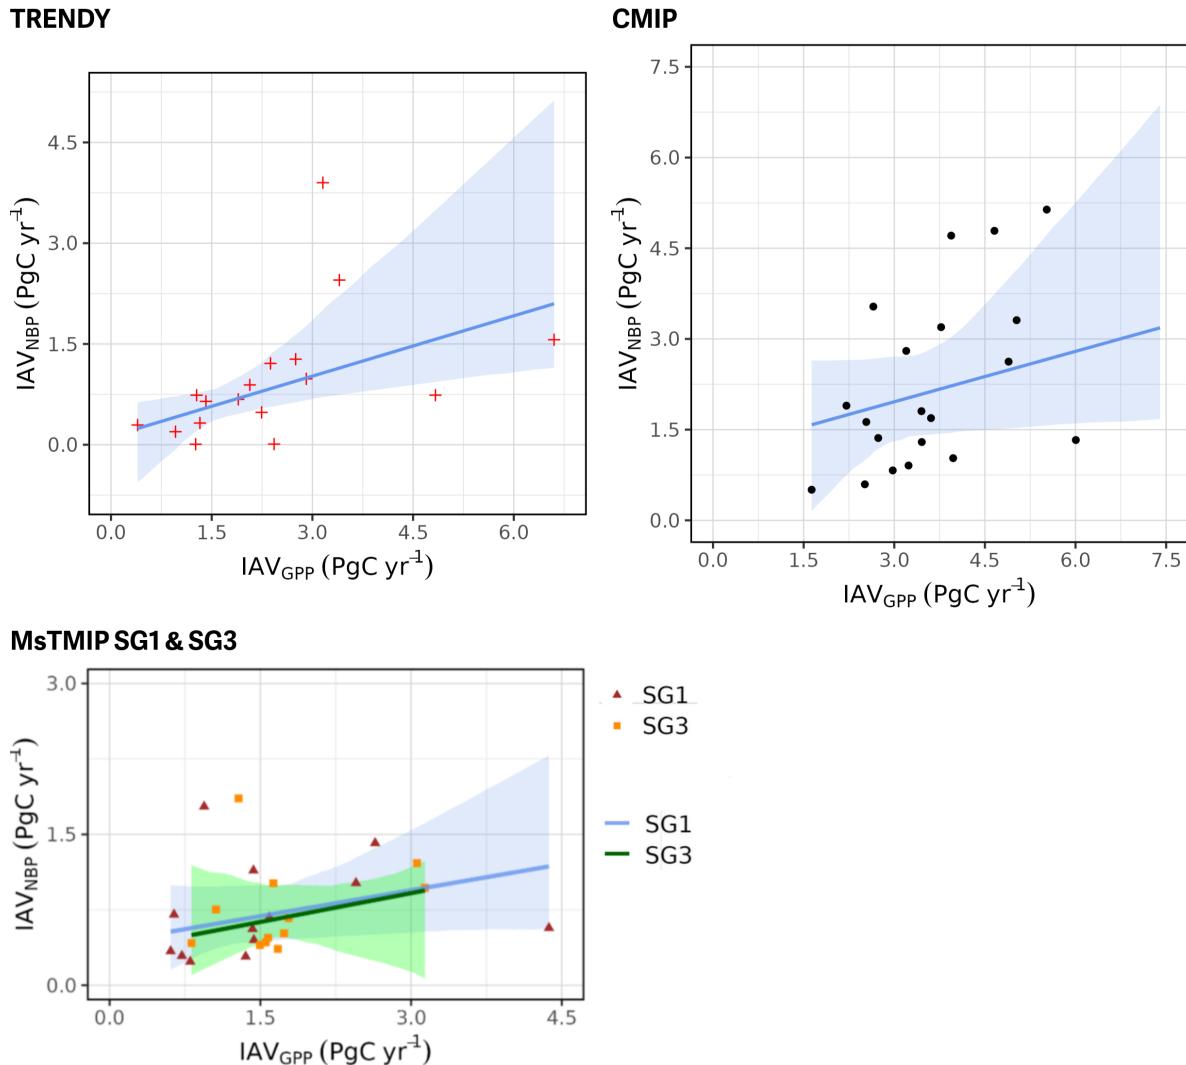


Abbildung 6: Streudiagramme der GPP- ggü. den NBP-IAV-Werten der TRENDY-, CMIP- und MsTMIP-Modellgruppen. Eingefärbte Flächen markieren das 95%-Konfidenzintervall der Bootstrapping-Verteilung robuster Regressionen über die Schätzungen des jeweiligen Ensembles. Abgetragene Linien zeigen die Median-Regression der Verteilung.

5 Diskussion

In der vorliegenden Arbeit grenzen wir zwischenjährliche Schwankungen in globaler GPP durch die Anwendung eines Emergent-Constraint ein. Dazu stützen wir uns auf die positive Kopplung der Variabilität in GPP mit jener in NBP, wie sie durch vorausgehende Untersuchungen für prozessbasierte Modelle gezeigt wurden (Poulter et al., 2014; Ahlström et al., 2015). Wir finden für alle berücksichtigten Simulationen eine positiv-monotone Kopplung zwischen der IAV in GPP und jener in NBP, wobei diese unterschiedlich stark ausfallen: CMIP-Modelle bilden die Beziehung mit rund drei mal höheren Werten in GPP steiler ab als TRENDY- und die MsTMIP-Simulationen, die einen doppelt so hohen Median der IAV in GPP ggü. jener in NBP schätzen. Wie lassen sich diese Unterschiede nun erklären? Wir sehen den Überlegungen von O’Sullivan et al. (2022) folgend drei Erklärungsstränge, entlang derer Unterschiede in den Modellschätzungen auf unterschiedliche Modellspezifikationen zurückgeführt werden können: Zunächst lassen sich unterschiedliche Schätzungen durch die Abbildung unterschiedlicher Prozesse erklären. So führt die Tabelle in Anhang A.3 für das TRENDY-Ensemble eine Reihe von Prozessen an, die jeweils nur in einem Teil der Modelle abgebildet werden. Während für viele dieser Prozesse gut verstanden ist, wie sich ihre Berücksichtigung in Unterschieden in den geschätzten Absolutwerten in GPP und NBP niederschlagen, bleiben die Auswirkungen von deren Integration auf die Variabilitäten der Modellschätzungen oft undurchsichtig. So führt die Integration von zusätzlichen Störungsquellen, bspw. im Zuge der Simulierung von natürlich auftretenden Feuern, bei gleichem Kohlenstoffinput zu mehr Verlusten und damit tieferem NBP-Level. Gleichzeitig schlägt sich diese jedoch nur in einer Veränderung der Variabilität von NBP nieder, wenn entsprechende Verluste nicht stationär verteilt sind, sondern mit klimatischen Determinanten kovariieren. Wir konnten entlang der unterschiedlichen Abbildung der in A.3 aufgeführten Prozesse kein konsistentes Muster zur Erklärung der beobachteten Unterschiede in der geschätzten NBP-IAV ableiten. Modellunterschiede können weiter auf die unterschiedliche Abbildung der selben Prozesse zurückgehen, so bspw. die Berücksichtigung unterschiedlicher Photosynthese-Modelle. Schliesslich können im Rahmen der Abbildung der selben Prozesse unter dem selben konzeptionellen Ansatz unterschiedliche Parametrisierung und Sensitivitäten angenommen werden. Schliesslich erzeugt das Zusammenspiel dieser „Unterschiedsquellen“ (Prozess-Ein/Aus, Prozessformulierung, Parametrisierung) Interaktionen und Überlagerungen, die die Formulierung klarer

Ursache-Wirkung-Zuschreibungen weiter erschweren. Diese Schwierigkeiten unterstreichen die Notwendigkeit eines systematischen Attributionsschemas und gezielter Faktorläufe und verweisen sogleich auf die Limitationen der vorliegenden Arbeit.

6 Literaturverzeichnis

- Ahlström, A., Raupach, M. R., Schurgers, G., Smith, B., Arneth, A., Jung, M., Reichstein, M., Canadell, J. G., Friedlingstein, P., Jain, A. K., Kato, E., Poulter, B., Sitch, S., Stocker, B. D., Viovy, N., Wang, Y. P., Wiltshire, A., Zaehle, S., and Zeng, N. (2015). The dominant role of semi-arid ecosystems in the trend and variability of the land CO₂ sink. *Science*, 348(6237):895–899. Publisher: American Association for the Advancement of Science.
- Anav, A., Friedlingstein, P., Beer, C., Ciais, P., Harper, A., Jones, C., Murray-Tortarolo, G., Papale, D., Parazoo, N. C., Peylin, P., Piao, S., Sitch, S., Viovy, N., Wiltschko, A., and Zhao, M. (2015). Spatiotemporal patterns of terrestrial gross primary production: A review. *Reviews of Geophysics*, 53(3):785–818. eprint: <https://agupubs.onlinelibrary.wiley.com/doi/pdf/10.1002/2015RG000483>.
- Bloomfield, K. J., Stocker, B. D., Keenan, T. F., and Prentice, I. C. (2023). Environmental controls on the light use efficiency of terrestrial gross primary production. *Global Change Biology*, 29(4):1037–1053. eprint: <https://onlinelibrary.wiley.com/doi/pdf/10.1111/gcb.16511>.
- Brönnimann, S. (2018). *Klimatologie*, chapter 3: Strahlung und Energie, pages 67–89. Haupt Bern, Stuttgart, Deutschland.
- Cox, P. M., Pearson, D., Booth, B. B., Friedlingstein, P., Huntingford, C., Jones, C. D., and Luke, C. M. (2013). Sensitivity of tropical carbon to climate change constrained by carbon dioxide variability. *Nature*, 494(7437):341–344. Publisher: Nature Publishing Group.
- Cramer, W., Kicklighter, D. W., Bondeau, A., Iii, B. M., Churkina, G., Nemry, B., Ruimy, A., Schloss, A. L., and Intercomparison, T. P. O. T. P. N. M. (1999). Comparing global models of terrestrial net primary productivity (NPP): overview and key results. *Global Change Biology*, 5(S1):1–15. eprint: <https://onlinelibrary.wiley.com/doi/pdf/10.1046/j.1365-2486.1999.00009.x>.
- De, R., Bao, S., Koirala, S., Brenning, A., Reichstein, M., Tagesson, T., Liddell, M., Ibrom, A., Wolf, S., Šigut, L., Hörttnagl, L., Woodgate, W., Korkiakoski, M., Merbold, L., Black,

- T. A., Roland, M., Klosterhalfen, A., Blanken, P. D., Knox, S., Sabbatini, S., Gielen, B., Montagnani, L., Fensholt, R., Wohlfahrt, G., Desai, A. R., Paul-Limoges, E., Galvagno, M., Hammerle, A., Jocher, G., Reverter, B. R., Holl, D., Chen, J., Vitale, L., Arain, M. A., and Carvalhais, N. (2025). Addressing Challenges in Simulating Inter–Annual Variability of Gross Primary Production. *Journal of Advances in Modeling Earth Systems*, 17(5):e2024MS004697.
- De Kauwe, M. G., Keenan, T. F., Medlyn, B. E., Prentice, I. C., and Terrer, C. (2016). Satellite based estimates underestimate the effect of CO₂ fertilization on net primary productivity. *Nature Climate Change*, 6(10):892–893. Publisher: Nature Publishing Group.
- Durack, P. J., Taylor, K. E., Gleckler, P. J., Meehl, G. A., Lawrence, B. N., Covey, C., Stouffer, R. J., Levavasseur, G., Ben-Nasser, A., Denvil, S., Stockhouse, M., Gregory, J. M., Juckes, M., Ames, S. K., Antonio, F., Bader, D. C., Dunne, J. P., Ellis, D., Eyring, V., Fiore, S. L., Joussaume, S., Kershaw, P., Lamarque, J.-F., Lautenschlager, M., Lee, J., Mauzey, C. F., Mzielinski, M., Nassisi, P., Nuzzo, A., O’Rourke, E., Painter, J., Potter, G. L., Rodriguez, S., and Williams, D. N. (2025). The Coupled Model Intercomparison Project (CMIP): Reviewing project history, evolution, infrastructure and implementation. *EGUsphere*, pages 1–74. Publisher: Copernicus GmbH.
- Eyring, V., Bony, S., Meehl, G. A., Senior, C. A., Stevens, B., Stouffer, R. J., and Taylor, K. E. (2016). Overview of the Coupled Model Intercomparison Project Phase 6 (CMIP6) experimental design and organization. *Geoscientific Model Development*, 9(5):1937–1958. Publisher: Copernicus GmbH.
- Farquhar, G. D., von Caemmerer, S., and Berry, J. A. (1980). A biochemical model of photosynthetic CO–2 assimilation in leaves of C–3 species. *Planta*, 149:78–90.
- Franklin, O., Johansson, J., Dewar, R. C., Dieckmann, U., McMurtrie, R. E., Bränström, Å., and Dybzinski, R. (2012). Modeling carbon allocation in trees: a search for principles. *Tree Physiology*, 32:648–666.
- Friedlingstein, P., O’Sullivan, M., Jones, M. W., Andrew, R. M., Bakker, D. C. E., Hauck, J., Le Quéré, C., Peters, G. P., Peters, W., Pongratz, J., Sitch, S., Canadell, J. G., Ciais, P., Jackson, R. B., Alin, S., Anthoni, P., Bates, N. R., Becker, M., Bellouin, N.,

Bopp, L., Chau, T. T. T., Chevallier, F., Chini, L., Cronin, M., Currie, K., Decharme, B., Djeutchouang, L., Dou, X., Evans, W., Feely, R. A., Feng, L., Gasser, T., Gilfillan, D., Gkritzalis, T., Grassi, G., Gregor, L., Gruber, N., Günther, D., Harris, I., Hartung, K., Houghton, R. A., Hurt, G. C., Iida, Y., Ilyina, T., Luijkx, I. T., Jain, A. K., Jones, S. D., Kato, E., Kennedy, D., Klein Goldewijk, K., Knauer, J., Korsbakken, J. I., Kóvér, G., Landschützer, P., Lefèvre, N., Lienert, S., Liu, Z., Lombardozzi, D., Marland, G., McGuire, P. C., Melton, J. R., Munro, D. R., Nabel, J. E. M. S., Nakaoka, S.-i., Niwa, Y., O'Brien, K., Ono, T., Pierrot, D., Poulter, B., Rehder, G., Resplandy, L., Robertson, E., Rödenbeck, C., Rosan, T. M., Schwinger, J., Schwingshackl, C., Séférian, R., Sutton, A. J., Sweeney, C., Tanhua, T., Tans, P. P., Tian, H., Tilbrook, B., van der Werf, G. R., Vuichard, N., Wada, C., Wanninkhof, R., Watson, A. J., Willis, D., Wiltshire, A. J., Yuan, W., Yue, C., Yue, X., Zaehle, S., Zeng, N., and Zheng, B. (2022). Global carbon budget 2021. *Earth System Science Data*, 14:1917–2005.

Friedlingstein, P., O'Sullivan, M., Jones, M. W., Andrew, R. M., Hauck, J., Landschützer, P., Le Quéré, C., Li, H., Luijkx, I. T., Olsen, A., Peters, G. P., Peters, W., Pongratz, J., Schwingshackl, C., Sitch, S., Canadell, J. G., Ciais, P., Jackson, R. B., Alin, S. R., Arneth, A., Arora, V., Bates, N. R., Becker, M., Bellouin, N., Berghoff, C. F., Bittig, H. C., Bopp, L., Cadule, P., Campbell, K., Chamberlain, M. A., Chandra, N., Chevallier, F., Chini, L. P., Colligan, T., Decayeux, J., Djeutchouang, L. M., Dou, X., Duran Rojas, C., Enyo, K., Evans, W., Fay, A. R., Feely, R. A., Ford, D. J., Foster, A., Gasser, T., Gehlen, M., Gkritzalis, T., Grassi, G., Gregor, L., Gruber, N., Gürses, , Harris, I., Hefner, M., Heinke, J., Hurt, G. C., Iida, Y., Ilyina, T., Jacobson, A. R., Jain, A. K., Jarníková, T., Jersild, A., Jiang, F., Jin, Z., Kato, E., Keeling, R. F., Klein Goldewijk, K., Knauer, J., Korsbakken, J. I., Lan, X., Lauvset, S. K., Lefèvre, N., Liu, Z., Liu, J., Ma, L., Maksyutov, S., Marland, G., Mayot, N., McGuire, P. C., Metzl, N., Monacci, N. M., Morgan, E. J., Nakaoka, S.-I., Neill, C., Niwa, Y., Nützel, T., Olivier, L., Ono, T., Palmer, P. I., Pierrot, D., Qin, Z., Resplandy, L., Roobaert, A., Rosan, T. M., Rödenbeck, C., Schwinger, J., Smallman, T. L., Smith, S. M., Sospedra-Alfonso, R., Steinhoff, T., Sun, Q., Sutton, A. J., Séférian, R., Takao, S., Tatebe, H., Tian, H., Tilbrook, B., Torres, O., Tourigny, E., Tsujino, H., Tubiello, F., van der Werf, G., Wanninkhof, R., Wang, X., Yang, D., Yang, X., Yu, Z., Yuan, W., Yue, X., Zaehle, S., Zeng, N., and Zeng, J. (2025). Global Carbon Budget 2024. *Earth System Science Data*,

- 17(3):965–1039. Publisher: Copernicus GmbH.
- Guo, Y., Yu, Y., Lin, P., Liu, H., He, B., Bao, Q., Zhao, S., and Wang, X. (2020). Overview of the CMIP6 Historical Experiment Datasets with the Climate System Model CAS FGOALS-f3-L. *Advances in Atmospheric Sciences*, 37(10):1057–1066. Publisher: Springer Science and Business Media LLC.
- He, M., Ju, W., Zhou, Y., Chen, J., He, H., Wang, S., Wang, H., Guan, D., Yan, J., Li, Y., Hao, Y., and Zhao, F. (2013). Development of a two-leaf light use efficiency model for improving the calculation of terrestrial gross primary productivity. *Agricultural and Forest Meteorology*, 173:28–39.
- Hilker, T., Coops, N. C., Wulder, M. A., Black, T. A., and Guy, R. D. (2008). The use of remote sensing in light use efficiency based models of gross primary production: A review of current status and future requirements. *Science of The Total Environment*, 404(2):411–423.
- Huber, P. J. (1981). *Robust Statistics*. Wiley.
- Humphrey, V., Zscheischler, J., Ciais, P., Gudmundsson, L., Sitch, S., and Seneviratne, S. I. (2018). Sensitivity of atmospheric CO₂ growth rate to observed changes in terrestrial water storage. *Nature*, 560(7720):628–631. Publisher: Nature Publishing Group.
- Huntzinger, D. N., Schwalm, C., Michalak, A. M., Schaefer, K., King, A. W., Wei, Y., Jacobson, A., Liu, S., Cook, R. B., Post, W. M., Berthier, G., Hayes, D., Huang, M., Ito, A., Lei, H., Lu, C., Mao, J., Peng, C. H., Peng, S., Poulter, B., Ricciuto, D., Shi, X., Tian, H., Wang, W., Zeng, N., Zhao, F., and Zhu, Q. (2013). The North American Carbon Program Multi-Scale Synthesis and Terrestrial Model Intercomparison Project – Part 1: Overview and experimental design. *Geoscientific Model Development*, 6(6):2121–2133. Publisher: Copernicus GmbH.
- Jung, M., Schwalm, C., Migliavacca, M., Walther, S., Camps-Valls, G., Koirala, S., Anthoni, P., Besnard, S., Bodesheim, P., Carvalhais, N., Chevallier, F., Gans, F., Goll, D., Haverd, V., Köhler, P., Ichii, K., Jain, A., Liu, J., Lombardozzi, D., and Reichstein, M. (2020). Scaling carbon fluxes from eddy covariance sites to globe: synthesis and evaluation of the FLUXCOM approach. *Biogeosciences*, 17:1343–1365.

Keenan, T., Baker, I., Barr, A., Ciais, P., Davis, K., Dietze, M., Dragoni, D., Gough, C. M., Grant, R., Hollinger, D., Hufkens, K., Poulter, B., McCaughey, H., Racza-ka, B., Ryu, Y., Schaefer, K., Tian, H., Verbeeck, H., Zhao, M., and Richardson, A. D. (2012). Terrestrial biosphere model performance for inter-annual variability of land-atmosphere CO₂ exchange. *Global Change Biology*, 18(6):1971–1987. eprint: <https://onlinelibrary.wiley.com/doi/pdf/10.1111/j.1365-2486.2012.02678.x>.

Keenan, T. and Williams, C. (2018). The Terrestrial Carbon Sink. *Annual Review of Environment and Resources*, 43(1):219–243.

Keenan, T. F., Prentice, I. C., Canadell, J. G., Williams, C. A., Wang, H., Raupach, M., and Collatz, G. J. (2016). Recent pause in the growth rate of atmospheric CO₂ due to enhanced terrestrial carbon uptake. *Nature Communications*, 7(1):13428. Publisher: Nature Publishing Group.

Knorr, W., Gobron, N., Scholze, M., Kaminski, T., Schnur, R., and Pinty, B. (2007). Impact of terrestrial biosphere carbon exchanges on the anomalous CO₂ increase in 2002–2003. *Geophysical Research Letters*, 34(9). eprint: <https://agupubs.onlinelibrary.wiley.com/doi/pdf/10.1029/2006GL029019>.

Konings, A. G., Williams, A. P., and Gentine, P. (2017). Sensitivity of grassland productivity to aridity controlled by stomatal and xylem regulation. *Nature Geoscience*, 10:284–288.

Lan, X., Tans, P., and Thoning, K. W. (2025). Trends in globally-averaged CO₂ determined from NOAA global monitoring laboratory measurements. <https://doi.org/10.15138/9NOH-ZH07>. Version Monday, 14-Jul-2025 16:12:30 MDT.

Le Quéré, C., Andrew, R. M., Friedlingstein, P., Sitch, S., Pongratz, J., Manning, A. C., Korsbakken, J. I., Peters, G. P., Canadell, J. G., Jackson, R. B., Boden, T. A., Tans, P. P., Andrews, O. D., Arora, V. K., Bakker, D. C. E., Barbero, L., Becker, M., Betts, R. A., Bopp, L., Chevallier, F., Chini, L. P., Ciais, P., Cosca, C. E., Cross, J., Currie, K., Gasser, T., Harris, I., Hauck, J., Haverd, V., Houghton, R. A., Hunt, C. W., Hurt, G., Ilyina, T., Jain, A. K., Kato, E., Kautz, M., Keeling, R. F., Klein Goldewijk, K., Kötzinger, A., Landschützer, P., Lefèvre, N., Lenton, A., Lienert, S., Lima, I., Lombardozzi, D., Metzl, N., Millero, F., Monteiro, P. M. S., Munro, D. R., Nabel, J.

- E. M. S., Nakaoka, S.-i., Nojiri, Y., Padin, X. A., Peregon, A., Pfeil, B., Pierrot, D., Poulter, B., Rehder, G., Reimer, J., Rödenbeck, C., Schwinger, J., Séférian, R., Skjelvan, I., Stocker, B. D., Tian, H., Tilbrook, B., Tubiello, F. N., van der Laan-Luijkx, I. T., van der Werf, G. R., van Heuven, S., Viovy, N., Vuichard, N., Walker, A. P., Watson, A. J., Wiltshire, A. J., Zaehle, S., and Zhu, D. (2018). Global Carbon Budget 2017. *Earth System Science Data*, 10(1):405–448. Publisher: Copernicus GmbH.
- Luo, Y. and Weng, E. (2011). Dynamic disequilibrium of the terrestrial carbon cycle under global change. *Trends in Ecology & Evolution*, 26(2):96–104.
- Monteith, J. L. (1972). Solar Radiation and Productivity in Tropical Ecosystems. *Journal of Applied Ecology*, 9(3):747–766. Publisher: [British Ecological Society, Wiley].
- Pei, Y., Dong, J., Zhang, Y., Yuan, W., Doughty, R., Yang, J., Zhou, D., Zhang, L., and Xiao, X. (2022). Evolution of light use efficiency models: Improvement, uncertainties, and implications. *Agricultural and Forest Meteorology*, 317:108905.
- Piao, S., Sitch, S., Ciais, P., Friedlingstein, P., Peylin, P., Wang, X., Ahlström, A., Anav, A., Canadell, J. G., Cong, N., Huntingford, C., Jung, M., Levis, S., Levy, P. E., Li, J., Lin, X., Lomas, M. R., Lu, M., Luo, Y., Ma, Y., Myneni, R. B., Poulter, B., Sun, Z., Wang, T., Viovy, N., Zaehle, S., and Zeng, N. (2013). Evaluation of terrestrial carbon cycle models for their response to climate variability and to CO₂ trends. *Global Change Biology*, 19(7):2117–2132. eprint: <https://onlinelibrary.wiley.com/doi/pdf/10.1111/gcb.12187>.
- Poulter, B., Frank, D., Ciais, P., Myneni, R. B., Andela, N., Bi, J., Broquet, G., Canadell, J. G., Chevallier, F., Liu, Y. Y., Running, S. W., Sitch, S., and van der Werf, G. R. (2014). Contribution of semi-arid ecosystems to interannual variability of the global carbon cycle. *Nature*, 509(7502):600–603. Publisher: Nature Publishing Group.
- Prentice, I. C., Dong, N., Gleason, S. M., Maire, V., and Wright, I. J. (2014). Balancing the costs of carbon gain and water transport: testing a new theoretical framework for plant functional ecology. *Ecology Letters*, 17:82–91.
- Reichstein, M., Bahn, M., Ciais, P., Frank, D., Mahecha, M. D., Seneviratne, S. I., Zscheischler, J., Beer, C., Buchmann, N., Frank, D. C., Papale, D., Rammig, A., Smith, P., Thonicke, K., van der Velde, M., Vicca, S., Walz, A., and Wattenbach, M. (2013).

- Climate extremes and the carbon cycle. *Nature*, 500(7462):287–295. Publisher: Nature Publishing Group.
- Running, S., Nemani, R., Heinsch, F., Zhao, M., Reeves, M., and Hashimoto, H. (2004). A continuous satellite-derived measure of global terrestrial primary production. *BioScience*, 54(6):547–560.
- Schulze, E.-D., Beck, E., Buchmann, N., Clemens, S., Müller-Hohenstein, K., and Scherer-Lorenzen, M. (2019). Approaches to Model Processes at the Ecosystem Level. In Schulze, E.-D., Beck, E., Buchmann, N., Clemens, S., Müller-Hohenstein, K., and Scherer-Lorenzen, M., editors, *Plant Ecology*, pages 513–527. Springer, Berlin, Heidelberg.
- Sitch, S., O’Sullivan, M., Robertson, E., Friedlingstein, P., Albergel, C., Anthoni, P., Arneth, A., Arora, V. K., Bastos, A., Bastrikov, V., Bellouin, N., Canadell, J. G., Chini, L., Ciais, P., Falk, S., Harris, I., Hurttt, G., Ito, A., Jain, A. K., Jones, M. W., Joos, F., Kato, E., Kennedy, D., Klein Goldewijk, K., Kluzek, E., Knauer, J., Lawrence, P. J., Lombardozzi, D., Melton, J. R., Nabel, J. E. M. S., Pan, N., Peylin, P., Pongratz, J., Poulter, B., Rosan, T. M., Sun, Q., Tian, H., Walker, A. P., Weber, U., Yuan, W., Yue, X., and Zaehle, S. (2024). Trends and Drivers of Terrestrial Sources and Sinks of Carbon Dioxide: An Overview of the TRENDY Project. *Global Biogeochemical Cycles*, 38(7):e2024GB008102. eprint: <https://onlinelibrary.wiley.com/doi/pdf/10.1029/2024GB008102>.
- Stocker, B. (2024). Land in the earth system (v1.0). Zenodo.
- Stocker, B. D., Wang, H., Smith, N. G., Harrison, S. P., Keenan, T. F., Sandoval, D., Davis, T., and Prentice, I. C. (2020). P-model v1.0: an optimality-based light use efficiency model for simulating ecosystem gross primary production. *Geoscientific Model Development*, 13(3):1545–1581. Publisher: Copernicus GmbH.
- Stocker, B. D., Zscheischler, J., Keenan, T. F., Prentice, I. C., Seneviratne, S. I., and Peñuelas, J. (2019). Drought impacts on terrestrial primary production underestimated by satellite monitoring. *Nature Geoscience*, 12(4):264–270. Publisher: Nature Publishing Group.
- Wang, H., Prentice, I. C., and Davis, T. W. (2014). Biophysical constraints on gross primary production by the terrestrial biosphere. *Biogeosciences*, 11(20):5987–6001. Publisher: Copernicus GmbH.

- Wang, H., Prentice, I. C., Keenan, T. F., Davis, T. W., Wright, I. J., Cornwell, W. K., Evans, B. J., and Peng, C. (2017). Towards a universal model for carbon dioxide uptake by plants. *Nature Plants*, 3(9):734–741.
- Wang, S., Zhang, X., Hou, L., Sun, J., and Xu, M. (2024). Estimating global gross primary production using an improved MODIS leaf area index dataset. *Remote Sensing*, 16(19):3731.
- WCRP-CMIP CMIP6 CVs team (2025). Cmip6 controlled vocabulary: Source id lookup and citation guidance. <https://wcrp-cmip.github.io/CMIP6-CVs/docs/CMIP6-source-id.html>. Abgerufen am 6. Aug. 2025.
- Welp, L. R., Keeling, R. F., Meijer, H. A. J., Bollenbacher, A. F., Piper, S. C., Yoshimura, K., Francey, R. J., Allison, C. E., and Wahlen, M. (2011). Interannual variability in the oxygen isotopes of atmospheric CO_2 driven by El Niño. *Nature*, 477:579–582.
- Wild, B., Teubner, I., Moesinger, L., Zotta, R.-M., Forkel, M., van der Schalie, R., Sitch, S., and Dorigo, W. (2022). VODCA2GPP – a new, global, long-term (1988–2020) gross primary production dataset from microwave remote sensing. *Earth System Science Data*, 14(3):1063–1085. Publisher: Copernicus GmbH.
- Yuan, W., Cai, W., Xia, J., Chen, J., Liu, S., Dong, W., Merbold, L., Law, B., Arain, A., Beringer, J., Bernhofer, C., Black, A., Blanken, P. D., Cescatti, A., Chen, Y., Francois, L., Gianelle, D., Janssens, I. A., Jung, M., Kato, T., Kiely, G., Liu, D., Marcolla, B., Montagnani, L., Raschi, A., Roupsard, O., Varlagin, A., and Wohlfahrt, G. (2014). Global comparison of light use efficiency models for simulating terrestrial vegetation gross primary production based on the LaThuile database. *Agricultural and Forest Meteorology*, 192–193:108–120.
- Yuan, W., Xia, J., Song, C., and Wang, Y.-P. (2024). Simulating the land carbon sink: Progresses and challenges of terrestrial ecosystem models. *Agricultural and Forest Meteorology*, 358:110264.
- Zhang, Y., Xu, M., Chen, H., and Adams, J. (2009). Global pattern of NPP to GPP ratio derived from MODIS data: effects of ecosystem type, geographical location and climate. *Global Ecology and Biogeography*, 18(3):280–290. eprint: <https://onlinelibrary.wiley.com/doi/pdf/10.1111/j.1466-8238.2008.00442.x>.

Zhao, M. S., Heinsch, F. A., Nemani, R. R., and Running, S. W. (2005). Improvements of the modis terrestrial gross and net primary production global data set. *Remote Sensing of Environment*, 95:164–176.

Zheng, Y., Shen, R., Wang, Y., Li, X., Liu, S., Liang, S., Chen, J. M., Ju, W., Zhang, L., and Yuan, W. (2020). Improved estimate of global gross primary production for reproducing its long-term variation, 1982–2017. *Earth System Science Data*, 12(4):2725–2746. Publisher: Copernicus GmbH.

Ågren, G. I. and Andersson, F. O. (2011). *Terrestrial Ecosystem Ecology: Principles and Applications*. Cambridge University Press, Cambridge.

Daten- und Codeverfügbarkeit

Für die Reproduktion der vorgestellten Ergebnisse verweisen wir auf die Daten-Files und Prozess-Skripts des diese Arbeit begleitenden Git-Hub-Repositoriums:

https://github.com/TrinidadTimo/bSc_thesis/tree/main. Angaben zum Bezug der verwendeten Simulationsoutputs sind im Methodik-Kapitel angeführt.

Selbstständigkeitserklärung

Hiermit versichere ich, die vorliegende Arbeit eigenständig und nur mit den angegebenen Hilfsmitteln verfasst habe. Alle Texte, derer ich mich bedient habe, inklusive Quellen aus dem Internet, habe ich im Literaturverzeichnis aufgeführt. Wörtliche Übernahmen von Textpassagen Anderer habe ich als wörtliche Zitate gekennzeichnet. Ich habe auch die paraphrasierende Wiedergabe oder freie Übernahme fremder Gedanken durch Verweis auf einen Originaltext belegt. Falls ich Werkzeuge und Dienste der künstlichen Intelligenz eingesetzt habe oder die Arbeit von anderen Menschen habe gelesen lassen, habe ich dies in der Arbeit ausgewiesen. Ich versichere, dass die vorliegende Arbeit trotz Einsatz der etwaig aufgeführten Hilfsmittel und Unterstützungen im Wesentlichen meine eigene Leistung ist.

Mir ist bewusst, dass ein Verstoss gegen diese Vorgaben den Regeln der guten wissenschaftlichen Praxis widerspricht und ein Plagiat darstellt, das nach Richtlinien der Universität Bern geahndet werden kann. Damit diese und andere Arbeiten auf Plagiatssoftware überprüft werden können, erkläre ich mich damit einverstanden, dass die Universität Bern diese Arbeit mit einer Plagiatssoftware überprüft und in einer Datenbank speichert, mit deren Hilfe zukünftige Arbeiten auf Plagiatssoftware überprüft werden können.

Datum: 27.08.2025

Ort: Bern

Unterschrift: 

A Ergänzendes Material

A.1 Übersicht aller berücksichtigter Modelle

TRENDY			
CABLE-POP	CLASSIC	CLM5.0	E3SM
EDv3	IBIS	ISAM	JSBACH3.2
JULES	LPJ-GUESS	LPJmL	
LPX-Bern	OCN	ORCHIDEE	
SDGVM	VISIT	LPJ-wsl	

CMIP			
ACCESS-ESM1-5	CanESM5	CanESM5-1	TaiESM1
CESM2	CESM2-WACCM	CMCC-CM2-SR5	CMCC-ESM2
EC-Earth3-CC	EC-Earth3-Veg	EC-Earth3-Veg-LR	GFDL-ESM4
GISS-E2-2-H	INM-CM4-8	INM-CM5-0	SAM0-UNICON
IPSL-CM6A-LR	NorESM2-MM	MPI-ESM-1-2-HAM	
MPI-ESM-1-2-LR	NorESM2-LM	IPSL-CM6A-LR-INCA	

MsTMIP			
BIOME-BGC	CLASS-CTEM-N	CLM4.0	CLM4VIC
DLEM	GTEC	LPJwsl	
SiB3	SiBCASA	ORCHIDEE-LSCE	
TEM6	VEGAS2.1	VISIT	

Tabelle 2: Übersicht der im Rahmen unserer Arbeit berücksichtigten Modelle entlang der jeweiligen Intercomparison-Programme. Für die MsTMIP-Modelle arbeiten wir mit Outputs von zwei verschiedenen Simulationen.

A.2 Landkomponenten der CMIP-Modelle

CMIP	Landkomponente	In TRENDY	In MsTMIP
ACCESS-ESM1-5	CABLE2.4	DV	N
Can-ESM5-1	CLASS3.6/CTEM1.2	DV	N
Can-ESM5	CLASS3.6/CTEM1.2	DV	N
CESM2	CLM5.0	J	DV
CESM2	CLM5.0	J	DV
CMCC-CM2-SR5	CLM4.5	DV	DV
CMCC-ESM2	CLM4.5	DV	DV
EC-Earth3-CC	HTESSEL	N	N
EC-Earth3-Veg	HTESSEL	N	N
EC-Earth3-Veg-LR	HTESSEL	N	N
GFDL-ESM4	GFDL-LM3.0	N	N
INM-CM4-8	INM-LND1	N	N
INM-CM5-0	INM-LND1	N	N
IPSL-CM6A-LR	ORCHIDEEv2.0	DV	DV
IPSL-CM6A-LR-INCA	ORCHIDEEv2.0	DV	DV
MPI-ESM-1-2-HAM	JSBACH3.2	J	N
MPI-ESM1-2-LR	JSBACH3.2	J	N
NorESM2-LM	CLM	DV	DV
NorESM2-MM	CLM	DV	DV
SAM0-UNICON	CLM4.0	DV	J
TaiESM1	CLM4.0	DV	J

Tabelle 3: Übersicht der in den CMIP-ESMs genutzten DGVMs und deren Vorkommen in den TRENDY- und MsTMIP-Ensembles. Dabei bedeutet "J", dass das entsprechende Landmodell im jeweiligen Ensemble auftritt resp. "N", dass es nicht Teil der Simulationsgruppe ist. "DV"(*Different Version*) verweist auf die Integration früherer oder späterer Versionen des entsprechenden Modells.

A.3 Landkomponenten der CMIP-Modelle

Modell	Feuer	C-N-Interaktionen	Direkte & diffuse solare Einstrahlung
CABLE-POP	N	Y	Y
CLASSIC	Y	N	N
CLM5.0	Y	Y	Y
IBIS	Y	N	N
E3SM	Y	Y	Y
EDv3	Y	Y	N
OCNv2	N	Y	N
ISAM	N	Y	N
JSBACH3.2	Y	Y	N
JULES	Y	Y	Y
LPJ-GUESS	Y	Y	N
LPJml	Y	N	N
LPJwsl	Y	N	N
LPX-Bern	Y	Y	N
ORCHIDEEv3	N	Y	N
SDGVM	Y	Y	N
VISIT	Y	N	N

Tabelle 4: Berücksichtigung ausgewählter, für NBP relevante Prozesse in den einzelnen TRENDY-DGVMs. Einordnung basierend auf Friedlingstein et al., 2022, ergänzt durch Schaphoff et al., 2018, Yang et al., 2023, Ma. et al., 2021.